UCG
Univerzitet Crne Gore

GEOGRAFSKI INFORMACIONI SISTEMI

Kreiranje neprekidnih površi

Lekcija 3 · Interpolacija, trend površi, inverzne distance i kriging

Velibor Došljak
Prirodno-matematički fakultet
28. oktobar 2026.

Šta nas čeka u ovoj lekciji

1 **Interpolacija**
šta je, kada se koristi, globalne i lokalne metode

2 **Trend: prava i površi**
metoda najmanjih kvadrata, polinomi višeg reda

3 **Lokalne determinističke metode**
Tisenovi poligoni, inverzne distance

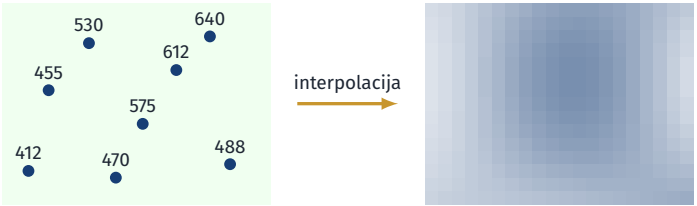
4 **Kriging**
kovarijansa, variogram, jednostavni kriging na primjeru

Glavno pitanje lekcije: kako iz mjerenja u konačnom broju tačaka procijeniti vrijednost u svakoj tački prostora?

01

Interpolacija

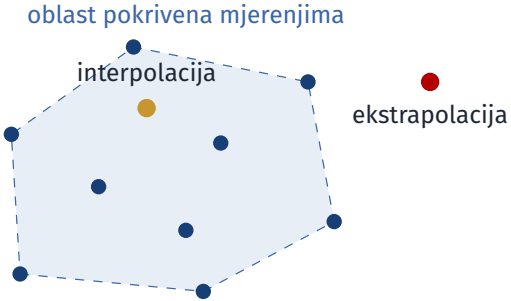
Šta je interpolacija



Mjerenja u tačkama **Procijenjena površ (raster)**

- **Interpolacija** je procjena vrijednosti atributa u proizvoljnoj lokaciji na osnovu mjerenja u tačkama istog regiona
- Tako se tačkasta opažanja pretvaraju u neprekidno polje (Lekcija 2: model polja)
- Primjeri: visina iz geodetskih tačaka, temperatura iz meteoroloških stanica

Interpolacija i ekstrapolacija



- Ako je tačka unutar oblasti koju pokrivaju mjerenja, govorimo o **interpolaciji**
- Ako je tačka izvan te oblasti, govorimo o **ekstrapolaciji**
- Ekstrapolacija je mnogo nepouzdanija: van uzorka nemamo podatke koji bi „ograničili“ procjenu

Kada se primjenjuje interpolacija

Premala rezolucija

površ ima manju rezoluciju od potrebne (DEM od 30 m, a treba 5 m)

Promjena mreže

prelazak rastera na drugu mrežu (druga ćelija ili koordinatni sistem)

Promjena modela

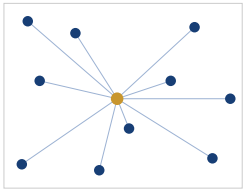
površ je u drugom modelu od potrebnog, npr. TIN umjesto rastera

Nepotpuni podaci

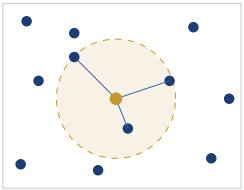
mjerenja ne pokrivaju cijelo područje od interesa

Rezultat se čuva kao **raster**, **izolinije** ili **TIN**, samostalno ili kao podloga drugim slojevima.

Globalne i lokalne metode



Globalni: sve tačke



Lokalni: samo susjedi

Globalne trend površi, regresioni modeli

Koriste **sve** podatke; služe više za otkrivanje opšteg trenda nego za samu interpolaciju.

Lokalne Tisenovi poligoni, inverzne distance, splajnovi, kriging

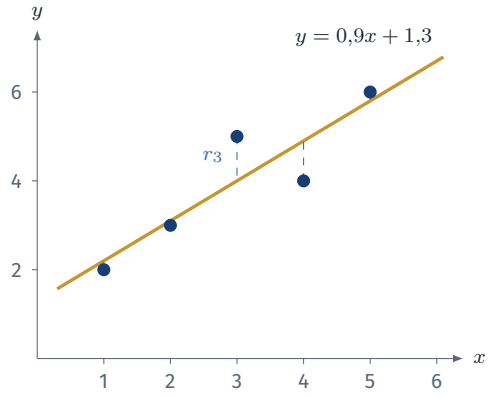
Koriste samo tačke iz **male zone** oko tačke koju procjenjujemo.

02

Linearni trend

Postavka problema

- Mjerenjem smo dobili parove (x_i, y_i), $i = 1, \ldots, n$
- x je nezavisno promjenljiva, y zavisno promjenljiva
- Primjer: x je godišnja količina padavina, y gustina vegetacije na istom mjestu
- Tražimo pravu $y = ax + b$ koja najbolje odgovara podacima
- Ima smisla kada je prirodno pretpostaviti da je zavisnost linearna



Metoda najmanjih kvadrata

- **Odstupanje** (rezidual) tačke i: $r_i = y_i - (ax_i + b)$
- Ukupno odstupanje mjerimo zbirom kvadrata:

$$F(a,b) = \sum_{i=1}^{n} \big(y_i - (ax_i + b)\big)^2$$

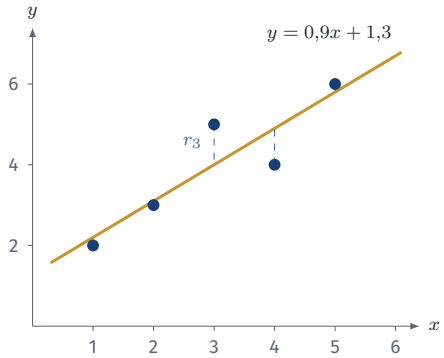
- Tražimo a i b za koje je F najmanje
- Parcijalni izvodi po a i b izjednačavaju se sa nulom

Normalne jednačine

$$\Big(\sum x_i^2\Big)a + \Big(\sum x_i\Big)b = \sum x_i y_i$$
$$\Big(\sum x_i\Big)a + n\,b = \sum y_i$$

Sistem 2×2 po nepoznatim a i b. Dobijeni model služi za procjenu y za bilo koje x.

Primjer: prava kroz pet tačaka



x_i	1	2	3	4	5	$\sum = 15$
y_i	2	3	5	4	6	$\sum = 20$
x_i^2	1	4	9	16	25	$\sum = 55$
$x_i y_i$	2	6	15	16	30	$\sum = 69$

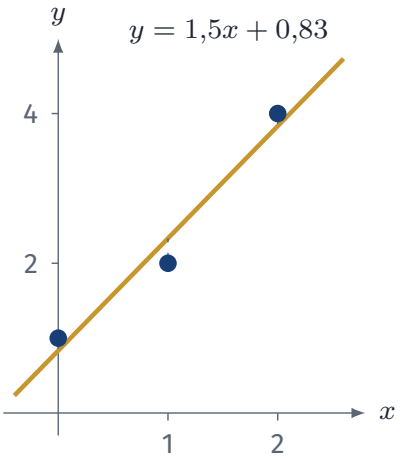
$55a + 15b = 69, \quad 15a + 5b = 20$

Iz druge: $b = 4 - 3a$; uvrštavanjem: $10a = 9$

$a = 0{,}9$, $b = 1{,}3$, tj. $y = 0{,}9x + 1{,}3$

Procjena za $x = 6$: $y = 6{,}7$

Matrični zapis i primjer sa tri tačke



Normalne jednačine u matričnom obliku:

$$\begin{bmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & n \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum x_i y_i \\ \sum y_i \end{bmatrix}$$

Tačke $(0,1)$, $(1,2)$, $(2,4)$: $\sum x_i = 3$, $\sum y_i = 7$, $\sum x_i^2 = 5$, $\sum x_i y_i = 10$, $n = 3$

$5a + 3b = 10, \quad 3a + 3b = 7$

$a = 1{,}5$, $b \approx 0{,}83$: $y = 1{,}5x + 0{,}83$

03

Trend površi

Od prave do polinoma

- Atribut z mjeren je duž linije u tačkama $x_1, \ldots, x_n$
- Ako z linearno raste sa x, uz male varijacije:

$$z(x) = b_0 + b_1 x + \varepsilon$$

- ε je šum: normalna raspodjela, nezavisan od x
- Ako zavisnost nije linearna, koristi se kvadratni model $z(x) = b_0 + b_1 x + b_2 x^2 + \varepsilon$ ili polinom višeg stepena

Oprez: preprilagođavanje

Dodavanjem članova polinom se može provući kroz bilo koji skup tačaka. Ali tada model prati i šum, a cilj je upravo da se šum **redukuje**.

Trend površi u dvije dimenzije

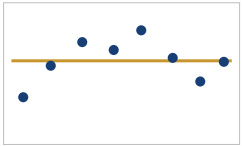
- Višestruka regresija po koordinatama x i y:

$$f(x,y) = \sum_{i+j \le p} b_{ij}\, x^i y^j$$

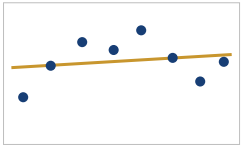
- Broj p je red trend površi
- Broj koeficijenata je $(p+1)(p+2)/2$
- Koeficijenti minimizuju $\sum_i \big[z(x_i,y_i) - f(x_i,y_i)\big]^2$; to radi svaki statistički paket

p	**Površ**	**Oblik**
0	horizontalna ravan	b_0
1	nagnuta ravan	$b_0 + b_1 x + b_2 y$
2	kvadratna	6 koeficijenata
3	kubna	10 koeficijenata

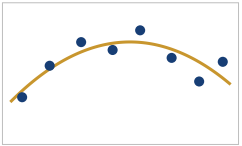
Trend površi različitog reda



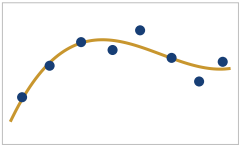
Red 0



Red 1



Red 2



Red 3

- Presjek površi duž jedne ose: isti uzorak, aproksimacija sve višeg reda
- Lokalne varijacije globalna metoda tretira kao slučajan šum
- Zato se trend površi rijetko koriste za direktnu interpolaciju; korisne su za **uklanjanje opšteg trenda** prije primjene lokalne metode

04

Lokalne determinističke metode

Zašto lokalne metode

- Očekujemo da je vrijednost u tački bliska vrijednostima u njenoj neposrednoj blizini
- Globalni model to zanemaruje
- Lokalna metoda traži četiri odluke:

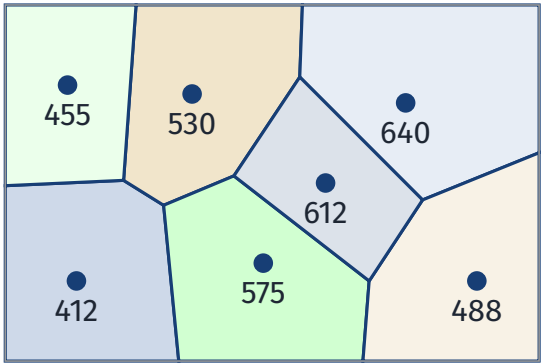
1. definisati područje pretrage
2. naći tačke sa podacima u tom području
3. izabrati matematičku funkciju
4. vrednovati rezultat (provjeriti grešku)

Prvi zakon geografije

„Sve je povezano sa svime, ali su bliže stvari povezanije od udaljenih.“

W. Tobler, 1970. Na ovoj ideji počivaju sve lokalne metode.

Tisenovi (Voronojevi) poligoni



- Svaka tačka dobija oblast svih lokacija kojima je najbliža
- Vrijednost u oblasti jednaka je vrijednosti u njenoj tački
- Najjednostavnija lokalna metoda: koristi samo jednog susjeda
- Površ je **stepenasta**: vrijednost skače na granicama
- Primjena: padavine po slivovima, zone opsluživanja stanica

Metod inverznih distanci (IDW)

- Procjenjujemo $z_0 = z(x_0, y_0)$ iz bliskih tačaka (x_i, y_i) sa vrijednostima z_i
- Rastojanje: $d_i = \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2}$
- Procjena je težinska sredina; bliže tačke imaju veću težinu
- Parametar p (obično 1 ili 2) određuje koliko brzo uticaj opada
- Procjena nikad ne izlazi iz opsega izmjerenih vrijednosti

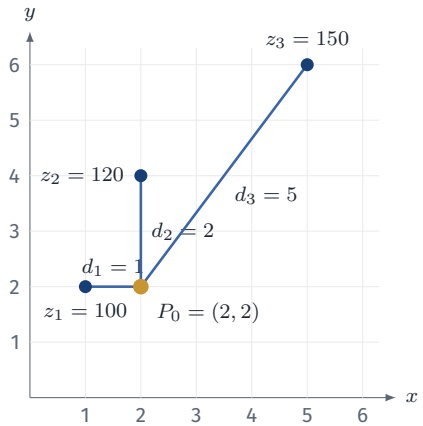
Formula

$$w_i = \frac{1}{d_i^p}, \qquad \hat{z}_0 = \frac{\sum_{i=1}^{n} w_i z_i}{\sum_{i=1}^{n} w_i}$$

Za $p = 1$: $c_i = \dfrac{1/d_i}{1/d_1 + \cdots + 1/d_n}$,
$\hat{z}_0 = c_1 z_1 + \cdots + c_n z_n$

Stvarna vrijednost je $z_0 = \hat{z}_0 + \varepsilon \approx \hat{z}_0$.

IDW na primjeru



	d_i	z_i	$1/d_i$	$1/d_i^2$
A_1	1	100	1	1
A_2	2	120	0,5	0,25
A_3	5	150	0,2	0,04
$\sum$			1,7	1,29

$$p = 1\text{: } \hat{z}_0 = \frac{100 + 60 + 30}{1{,}7} \approx \mathbf{111{,}8}$$

$$p = 2\text{: } \hat{z}_0 = \frac{100 + 30 + 6}{1{,}29} \approx \mathbf{105{,}4}$$

Veće p: najbliža tačka još više dominira.

Druge lokalne metode

Splajnovi

Površ se sastavlja od polinoma po djelovima, glatko spojenih na granicama. Daje „meke“ površi, ali može da pređe opseg podataka.

Linearna interpolacija u TIN-u

Vrijednost u tački dobija se iz tri tjemena trougla kome pripada (Lekcija 2). Brza i tačna u mjerenim tačkama.

Težinske metode

IDW je najpoznatija; težine se mogu birati i drugačije, npr. prema pravcu ili broju susjeda.

Deterministične metode daju procjenu, ali **ne i njenu pouzdanost**. To rješava kriging.

05

Kriging

Ideja krigovanja

- Metod je dobio ime po rudarskom inženjeru **D. Krigeu** (Južna Afrika), a teoriju je razvio G. Matheron
- Zasniva se na teoriji regionalizovane promjenljive
- Težine se ne biraju „na oko“ (kao $1/d$), već se računaju iz **prostorne korelacije** samih podataka
- Pored procjene daje i grešku procjene

Regionalizovana promjenljiva

$$Z(\mathbf{x}) = m(\mathbf{x}) + \varepsilon'(\mathbf{x}) + \varepsilon''$$

$m(\mathbf{x})$	strukturna komponenta (trend)
$\varepsilon'(\mathbf{x})$	prostorno korelisana varijacija
ε''	nekorelisani šum (Gaus)

Pretpostavke: stacionarnost

- Mjerenja posmatramo kao vrijednosti slučajne funkcije $Z(\mathbf{x})$
- **Stacionarnost** (drugog reda):
  - očekivanje je isto svuda: $E[Z(\mathbf{x})] = m$
  - kovarijansa zavisi samo od rastojanja: $\mathrm{Cov}(Z(\mathbf{x}), Z(\mathbf{x}+\mathbf{h})) = C(h)$
- Ako postoji trend, prvo se ukloni (Lekcija 3, trend površi)

Centriranje

$$Y(\mathbf{x}) = Z(\mathbf{x}) - m$$

Y je **centrirana** promjenljiva:

$$E[Y(\mathbf{x})] = 0$$

$$E[Y(\mathbf{x})\, Y(\mathbf{x}+\mathbf{h})] = C(h)$$

Jednostavni kriging radi sa Y, a na kraju vraća m.

Empirijski variogram

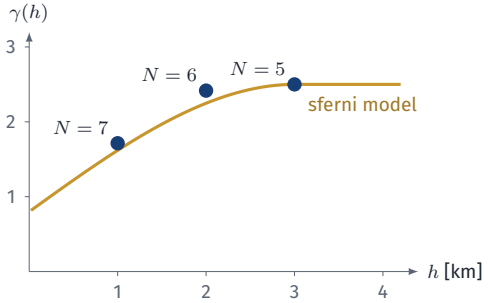
Variogram se procjenjuje iz podataka:

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \sum_{d_{ij} \approx h} (z_i - z_j)^2$$

$N(h)$: broj parova tačaka na rastojanju približno h.

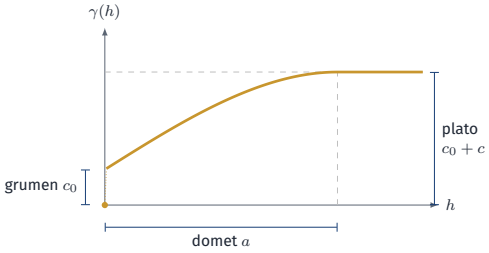
Primjer: profil sa mjerenjem na svaki km:
$z = 4,\ 6,\ 5,\ 7,\ 4,\ 3,\ 5,\ 6$

h	$N(h)$	$\sum(z_i - z_j)^2$	$\hat{\gamma}(h)$
1	7	24	1,71
2	6	29	2,42
3	5	25	2,50



Kroz tačke se provuče dozvoljeni model (ovdje sferni, $c_0 = 0{,}8$, plato 2,5, $a = 3$ km).

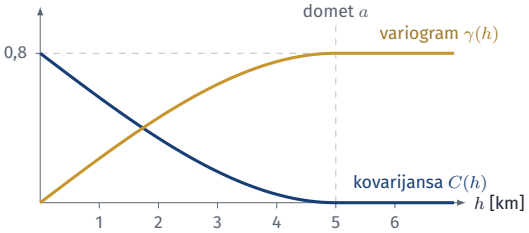
Modeli variograma



- **Grumen** c_0 (*nugget*): greška mjerenja i varijacija na rastojanjima manjim od razmaka tačaka
- **Plato** $c_0 + c$ (*sill*): varijansa podataka, $= C(0)$
- **Domet** a (*range*): dalje tačke nisu korelisane

Model	$\gamma(h) - c_0$ (za $h > 0$)
sferni	$c\big(1{,}5\frac{h}{a} - 0{,}5\frac{h^3}{a^3}\big),\ h \le a$
eksponencijalni	$c\big(1 - e^{-3h/a}\big)$
Gausov	$c\big(1 - e^{-3h^2/a^2}\big)$

Kovarijansa i variogram

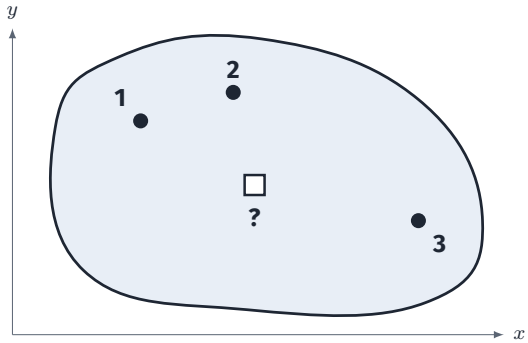


- Korelacija vrijednosti u dvije tačke opada sa rastojanjem h
- Opisujemo je funkcijom $C(h)$; npr. sferni model:

$$C(h) = 0{,}8\left(1 - 1{,}5\frac{h}{a} + 0{,}5\left(\frac{h}{a}\right)^3\right)$$

  za $h \leq a$, a $C(h) = 0$ za $h > a$
- $a = 5000$ m je **domet**: dalje tačke nisu korelisane
- **Variogram** $\gamma(h) = C(0) - C(h)$ mjeri različitost; u praksi se procjenjuje iz podataka

Postavka: tri mjerenja i nepoznata tačka

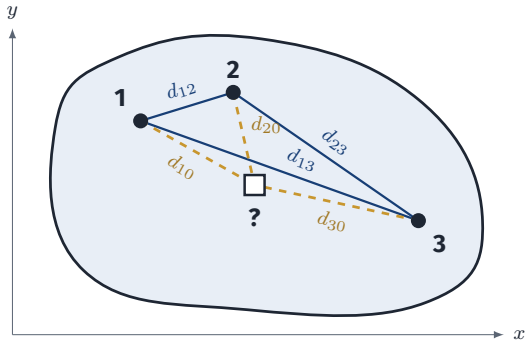


Poznate su vrijednosti u tačkama 1, 2 i 3.
Kolika je vrijednost u tački **?**

Procjena:

$$\hat{z}_0 = m + c_1(z_1 - m) + c_2(z_2 - m) + c_3(z_3 - m)$$

Postavka: tri mjerenja i nepoznata tačka

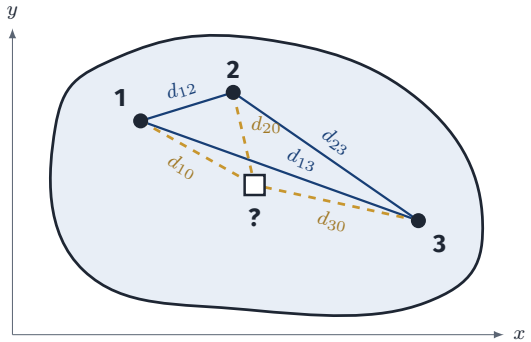


Isprekidano: rastojanja do nepoznate tačke $\Rightarrow$ vektor $\mathbf{b}$, $b_i = C(d_{i0})$

Puno: rastojanja *između* mjerenja $\Rightarrow$ matrica A, $a_{ij} = C(d_{ij})$

IDW koristi samo isprekidane linije; kriging koristi obje.

Postavka: tri mjerenja i nepoznata tačka



Primjer (sferni model, $C(0) = 0{,}8$, $a = 5$ km):

	1	2	3
d_{i0} [m]	1836	1334	2354
IDW ($p = 1$)	0,32	0,44	0,25
kriging	**0,20**	**0,45**	**0,26**

Tačka 1 je blizu tačke 2 ($d_{12} = 1360$ m), pa je djelimično zaklonjena: kriging joj smanjuje težinu. Ostatak težine ($0{,}10$) ide srednjoj vrijednosti m; $\sigma^2_{SK} \approx 0{,}44$.

Kriging je linearni estimator

- Procjena u A_0 je linearna kombinacija centriranih mjerenja:

$$\hat{Y}_0 = \sum_{i=1}^{n} c_i Y_i, \qquad \hat{Z}_0 = m + \sum_{i=1}^{n} c_i (Z_i - m)$$

- Greška procjene: $e = \hat{Y}_0 - Y_0$
- Tražimo težine koje daju **nepristrasnu** i **najtačniju** procjenu

Nepristrasnost

$$E[e] = \sum_i c_i \underbrace{E[Y_i]}_{0} - \underbrace{E[Y_0]}_{0} = 0$$

Zbog centriranja je procjena nepristrasna za bilo koje težine c_i: u prosjeku ne precjenjuje niti potcjenjuje.

Ali nepristrasnih procjena ima beskonačno mnogo. Koja je najbolja?

Varijansa greške

Mjera kvaliteta je varijansa greške (srednja kvadratna greška, jer je $E[e] = 0$):

$$\sigma^2(\mathbf{c}) = E\Big[\Big(\sum_i c_i Y_i - Y_0\Big)^2\Big] = \sum_i \sum_j c_i c_j \underbrace{E[Y_i Y_j]}_{C(d_{ij})=a_{ij}} - 2\sum_i c_i \underbrace{E[Y_i Y_0]}_{C(d_{i0})=b_i} + \underbrace{E[Y_0^2]}_{C(0)}$$

$$\sigma^2(\mathbf{c}) = \mathbf{c}^{\mathsf{T}} A\, \mathbf{c} - 2\,\mathbf{c}^{\mathsf{T}}\mathbf{b} + C(0)$$

Kvadratna funkcija težina; zavisi samo od položaja tačaka i kovarijanse, a ne od izmjerenih vrijednosti.

Zato se greška krigovanja može izračunati **prije** mjerenja, npr. pri planiranju mreže mjernih stanica.

Najbolja procjena: sistem krigovanja

Minimum: parcijalni izvodi su nula

$$\frac{\partial \sigma^2}{\partial c_i} = 2(A\mathbf{c})_i - 2b_i = 0 \implies \boxed{A\mathbf{c} = \mathbf{b}}$$

Varijansa u minimumu:

$$\sigma^2_{SK} = C(0) - \mathbf{c}^{*\mathsf{T}}\mathbf{b} = C(0) - \sum_i c_i^* b_i$$

Zašto baš najbolja?

Za bilo koje druge težine $\mathbf{c} = \mathbf{c}^* + \boldsymbol{\delta}$:

$$\sigma^2(\mathbf{c}) = \sigma^2(\mathbf{c}^*) + \boldsymbol{\delta}^{\mathsf{T}} A\, \boldsymbol{\delta}$$

jer je $A\mathbf{c}^* - \mathbf{b} = 0$. Kako je $\boldsymbol{\delta}^{\mathsf{T}} A \boldsymbol{\delta} = \mathrm{Var}\left(\sum \delta_i Y_i\right) \geq 0$, svaka druga linearna procjena ima veću ili jednaku grešku.

BLUE (*Best Linear Unbiased Estimator*): linearan po konstrukciji, nepristrasan zbog centriranja, najbolji jer minimizuje varijansu greške.

Jednostavni kriging

- U ravni je data veličina $z = z(x, y)$ (npr. visina terena ili koncentracija zlata), izmjerena u N tačaka; m je srednja vrijednost
- Procjenjujemo z_0 u tački $A_0(x_0, y_0)$
- Biramo n tačaka A_i najbližih tački A_0
- d_{ij} je rastojanje A_i i A_j, a d_{i0} rastojanje A_i i A_0

Postupak

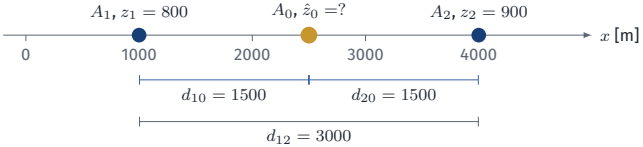
$a_{ij} = C(d_{ij})$: korelacija među tačkama uzorka

$b_i = C(d_{i0})$: veza tačke A_i sa A_0

Riješiti sistem $A\mathbf{c} = \mathbf{b}$, pa

$$\hat{z}_0 = m + c_1(z_1 - m) + \cdots + c_n(z_n - m)$$

Kriging na primjeru



Podaci: $m = 1000$, $a = 5000$

$a_{11} = a_{22} = C(0) = 0{,}8$
$a_{12} = C(3000) = 0{,}8 \cdot 0{,}208 \approx 0{,}17$
$b_1 = b_2 = C(1500) = 0{,}8 \cdot 0{,}564 \approx 0{,}45$

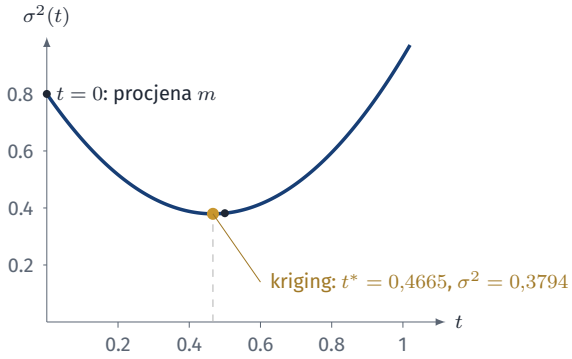
$0{,}8c_1 + 0{,}17c_2 = 0{,}45$
$0{,}17c_1 + 0{,}8c_2 = 0{,}45$

Rješenje: $c_1 = c_2 \approx 0{,}46$

$\hat{z}_0 = 1000 + 0{,}46(-200) + 0{,}46(-100) \approx \mathbf{860}$

$\sigma^2_{SK} = 0{,}8 - 2 \cdot 0{,}4665 \cdot 0{,}4508 \approx 0{,}38$

Na primjeru: kriging je zaista minimum



Zbog simetrije uzmimo $c_1 = c_2 = t$:

$$\sigma^2(t) = 0{,}8 - 1{,}803\,t + 1{,}933\,t^2$$

Težine	t	σ^2
procjena je m	0	0,800
	0,3	0,433
kriging	**0,4665**	**0,379**
prosta sredina	0,5	0,382
	0,8	0,594

Sve su nepristrasne; najmanju grešku ima kriging.

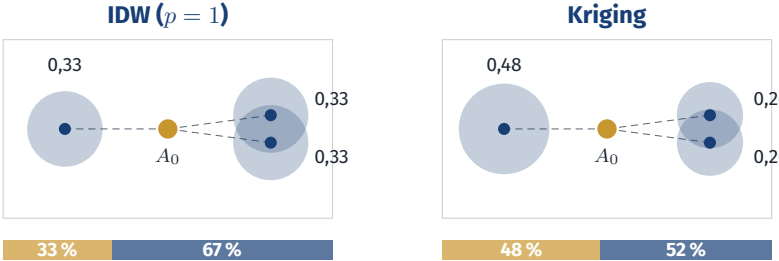
Demonstracija: simulacija

Tačka (c): $A_0 = (1000, 2000)$. Simulirali smo **200 000** realizacija polja sa kovarijansom $C(h)$ i za svaku izračunali grešku. Sve procjene su oblika $m + c_1(z_1 - m) + c_2(z_2 - m)$.

Procjena	c_1	c_2	**srednja greška**	**varijansa (sim.)**	**varijansa (teor.)**
kriging	0,429	0,017	$-0{,}0003$	**0,650**	**0,651**
Tisen (najbliža tačka)	1	0	$-0{,}0005$	0,906	0,909
IDW, $p = 1$	0,643	0,357	$-0{,}0006$	0,801	0,804
IDW, $p = 2$	0,765	0,235	$-0{,}0006$	0,800	0,804
prosta sredina	0,5	0,5	$-0{,}0006$	0,850	0,853
samo m	0	0	$0{,}0000$	0,801	0,800

Srednja greška je ≈ 0 za sve (nepristrasne), ali kriging ima najmanju varijansu; IDW ovdje nije bolji od same srednje vrijednosti. Simulacija potvrđuje formulu $\sigma^2(\mathbf{c})$.

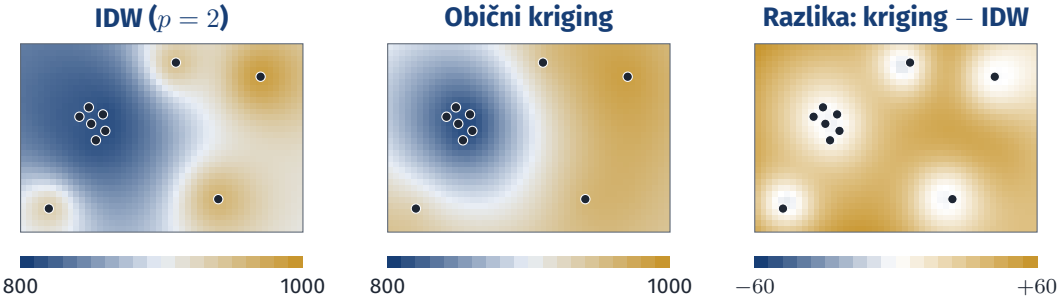
Kriging naspram IDW: grupisane tačke



udio usamljene tačke (lijevo) i para (desno) u procjeni

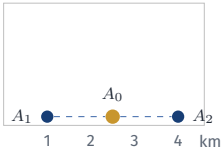
- Sve tri tačke su ≈ 1500 m od A_0, ali su dvije desne blizu jedna drugoj
- **IDW** gleda samo rastojanje do A_0: par dobija dvije trećine uticaja
- **Kriging** gleda i rastojanja *među* tačkama: par nosi skoro istu informaciju, pa dijeli težinu (deklasterovanje)

IDW i kriging u ravni

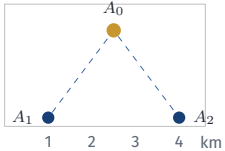


- Šest bliskih mjerenja niskih vrijednosti (lijevo) i četiri razbacana, viših
- **IDW** grupu broji šest puta: plava oblast se širi daleko od nje, a oko usamljenih tačaka su pikovi
- U tački $(3;\ 2)$ grupa ima težinu **0,74** kod IDW i **0,45** kod krigovanja: procjene 849 i 891; razlika je najveća između grupe i usamljenih tačaka

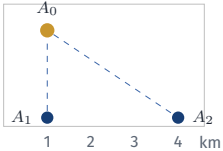
Kriging: tačka van prave



(a)



(b)

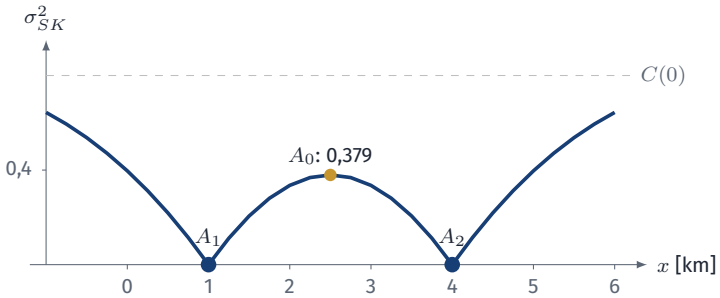


(c)

Položaj A_0	d_{10}	d_{20}	c_1	c_2	$\hat{z}_0$	σ^2_{SK}
(a) $(2500, 0)$	1500	1500	0,47	0,47	**860**	0,38
(b) $(2500, 2000)$	2500	2500	0,26	0,26	**922**	0,67
(c) $(1000, 2000)$	2000	3606	0,43	0,02	**913**	0,65

Što je A_0 dalje od uzorka, procjena je bliža srednjoj vrijednosti $m = 1000$; u (c) bliža tačka A_1 potpuno dominira.

Varijansa krigovanja: mapa pouzdanosti



- U mjerenim tačkama $\sigma^2 = 0$: kriging (bez grumena) je egzaktan interpolator
- Između tačaka greška raste, a daleko od uzorka teži platou $C(0)$
- U GIS-u se uz mapu procjene pravi i **mapa varijanse**: gdje treba još mjerenja

Obični kriging: nepoznata srednja vrijednost

- U praksi m nije poznato; procjena je $\hat{Z}_0 = \sum \lambda_i Z_i$
- $E[\hat{Z}_0 - Z_0] = m\left(\sum \lambda_i - 1\right)$, pa je procjena nepristrasna samo ako $\sum \lambda_i = 1$
- Minimum varijanse uz to ograničenje: **Lagranžov množilac** μ

$$\begin{bmatrix} A & \mathbf{1} \\ \mathbf{1}^{\mathsf{T}} & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{\lambda} \\ \mu \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ 1 \end{bmatrix}$$

$$\sigma^2_{OK} = C(0) - \boldsymbol{\lambda}^{\mathsf{T}}\mathbf{b} - \mu$$

Primjer (a): $\lambda_1 = \lambda_2 = 0{,}5$, $\mu \approx -0{,}032$
$\hat{z}_0 = 850$, $\sigma^2_{OK} \approx 0{,}382$

Primjer (c): $\lambda_1 \approx 0{,}71$, $\lambda_2 \approx 0{,}29$
$\hat{z}_0 \approx 829$, $\sigma^2_{OK} \approx 0{,}799$

Obični kriging ima veću grešku od jednostavnog (0,38 i 0,65), jer ne zna m: cijena nepoznate srednje vrijednosti.

Univerzalni kriging umjesto konstante m procjenjuje trend $m(\mathbf{x})$ (npr. ravan).

Kriging u praksi

1 **Istraživanje podataka**
histogram, izuzeci, trend

2 **Empirijski variogram**
parovi tačaka po klasama rastojanja

3 **Izbor modela**
tip i parametri c_0, plato, domet

4 **Unakrsna provjera**
izostavi tačku, procijeni je iz ostalih, uporedi

5 **Kriging**
sistem za svaku ćeliju rastera

6 **Dvije mape**
procjena i varijansa greške

Unakrsna provjera: prosječna greška treba da bude ≈ 0, a kvadrat greške blizak procijenjenoj varijansi.

Poređenje metoda

	Trend površi	Tisen	IDW	Kriging
Vrsta	globalna	lokalna	lokalna	geostatistička
Površ	glatka	stepenasta	„pikovi“	glatka
Prolazi kroz tačke	ne	da	da	da (bez šuma)
Greška procjene	ne	ne	ne	da
Složenost	mala	vrlo mala	mala	velika

U praksi: QGIS ima IDW i TIN interpolaciju u alatima za obradu, GDAL alat `gdal_grid`, a kriging nude SAGA GIS i R paket `gstat`.

REZIME

Ključne poruke

1. Interpolacija procjenjuje vrijednost iz okolnih mjerenja i pretvara tačke u neprekidno polje
2. Globalne metode (trend, regresija) hvataju opšti trend; lokalne koriste samo susjede
3. IDW je težinska sredina sa težinama $1/d^p$; Tisenovi poligoni koriste najbližu tačku
4. Kriging je najbolji linearni nepristrasni estimator: težine iz variograma minimizuju grešku

Sljedeća lekcija: Osnove kartografije

Hvala na pažnji

Pitanja?

UCG
Univerzitet Crne Gore