UCG
Univerzitet Crne Gore

GEOGRAFSKI INFORMACIONI SISTEMI

Kreiranje neprekidnih površi

Lekcija 3 · skripta za učenje

Velibor Došljak · Prirodno-matematički fakultet, Univerzitet Crne Gore

◎ Ciljevi lekcije

Kada pročitate ovu lekciju, trebalo bi da umijete da:

- objasnite šta je interpolacija, po čemu se razlikuje od ekstrapolacije i kada se koristi;
- razlikujete globalne i lokalne, odnosno determinističke i geostatističke metode;
- metodom najmanjih kvadrata odredite pravu koja najbolje odgovara podacima;
- objasnite trend površi i izračunate broj koeficijenata površi datog reda;
- procijenite vrijednost u tački metodom inverznih distanci i objasnite Tisenove poligone;
- objasnite ideju krigovanja i riješite jednostavan primjer sa dvije tačke.

Sadržaj

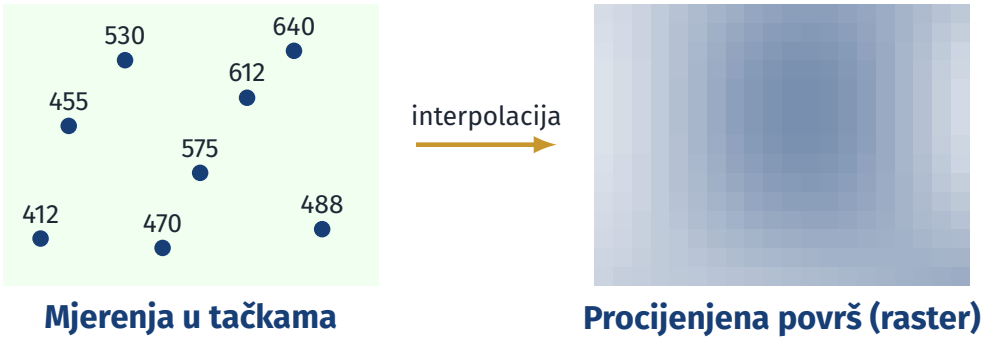
1 Interpolacija 2
2 Linearni trend 3
3 Trend površi 5
4 Lokalne determinističke metode 6
5 Kriging 9
Rezime 21
Pitanja za provjeru znanja 21
Zadaci za vježbu 22
Pojmovnik 23
Literatura 24

1 Interpolacija

1.1 Pojam interpolacije

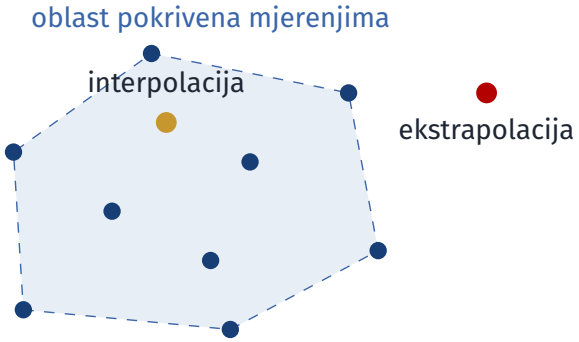
U prethodnoj lekciji vidjeli smo da se mnoge pojave (nadmorska visina, temperatura, koncentracija zagađenja) najprirodnije opisuju *modelom polja*: svakoj tački prostora pridružena je jedna vrijednost. Ali mjerenja nikad ne postoje u svakoj tački. Imamo geodetske tačke, meteorološke stanice ili mjerna mjesta, a vrijednost nam treba svuda. Taj jaz premošćuje interpolacija (slika 1).

> **Definicija : interpolacija**
> *Interpolacija* je postupak procjene vrijednosti nekog atributa u proizvoljnoj lokaciji na osnovu mjerenja izvršenih u tačkama koje se nalaze u istom regionu.



Slika 1. Od mjerenja u tačkama do procijenjene neprekidne površi.

Ako se tačka u kojoj procjenjujemo vrijednost nalazi *izvan* oblasti koju pokrivaju mjerenja, govorimo o **ekstrapolaciji** (slika 2). Ekstrapolacija je mnogo nepouzdanija od interpolacije, jer izvan uzorka nemamo podatke koji bi ograničili procjenu: greška može biti proizvoljno velika.



Slika 2. Tačka unutar oblasti pokrivene mjerenjima (interpolacija) i tačka izvan nje (ekstrapolacija).

1.2 Kada se primjenjuje

Interpolacija je potrebna kada:

- diskretizovana površ ima **manju rezoluciju** od zahtijevane (npr. imamo DEM sa ćelijom

od 30 m, a analiza traži 5 m);

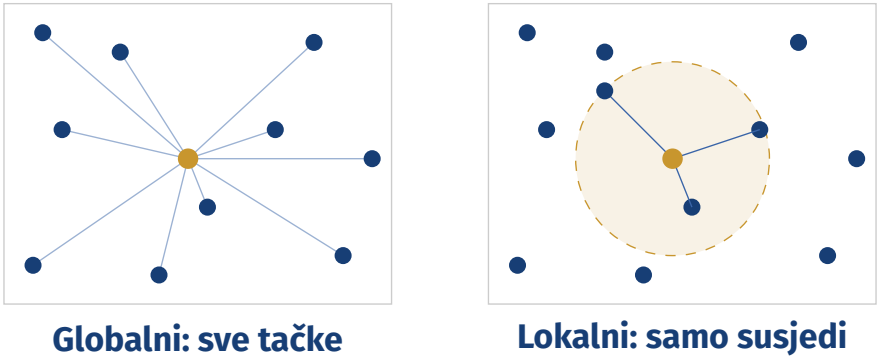
- raster treba prevesti iz jedne mreže u drugu (druga veličina ćelije, drugi koordinatni sistem);
- je neprekidna površ predstavljena **drugačijim modelom** od potrebnog, npr. površ treba prevesti iz TIN-a u raster i obratno;
- raspoloživi podaci **ne pokrivaju** kompletno područje od interesa, bilo da je uzorkovanje gusto ili rijetko.

Dobijena neprekidna površ može se koristiti samostalno ili kao podloga drugim slojevima u GIS-u. Zapisuje se na jedan od načina iz Lekcije 2: kao **raster**, kao skup **izolinija** ili kao **TIN**.

1.3 Podjela metoda

Metode interpolacije dijele se po dva kriterijuma.

Globalne i lokalne. **Globalni interpolatori** koriste sve dostupne podatke i daju procjenu za cijelo istraživano područje (trend površi, regresioni modeli, klasifikacija uz pomoć spoljašnjih informacija). Rijetko se koriste za direktnu interpolaciju; češće služe da se ispitaju i otklone efekti globalnih varijacija. **Lokalni interpolatori** rade u maloj zoni oko tačke koju procjenjujemo (Tisenovi poligoni, linearne težinske metode, splajnovi, kriging). Razliku prikazuje slika 3.



Slika 3. Globalni interpolator koristi sve tačke, a lokalni samo one u zoni pretrage.

Determinističke i geostatističke. **Determinističke** metode računaju procjenu po unaprijed zadatoj formuli (npr. težine $1/d$). **Geostatističke** metode, čiji je glavni predstavnik kriging, prvo iz podataka procijene kako se vrijednosti prostorno korelišu, pa tek onda računaju procjenu. Zato mogu da daju i procjenu greške.

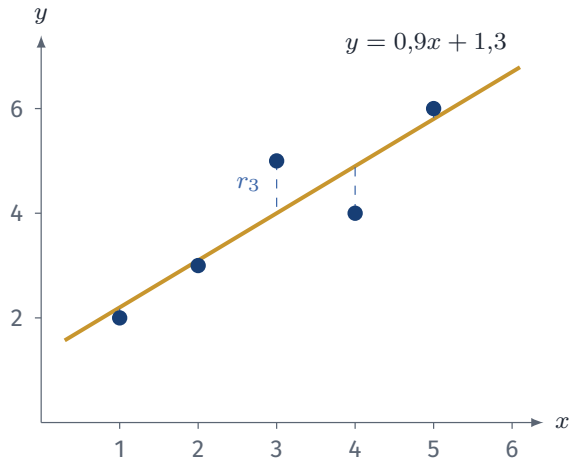
2 Linearni trend

2.1 Postavka problema

Najjednostavniji globalni model je prava linija. Pretpostavimo da su mjerenjem dobijeni parovi vrijednosti $(x_1, y_1), \ldots, (x_n, y_n)$, gdje je x nezavisno, a y zavisno promjenljiva. Na primjer, x može da bude godišnja količina padavina na nekom mjestu, a y gustina vegetacije na tom mjestu. Treba naći najbolju linearnu aproksimaciju ove zavisnosti, tj. pravu

$$y = ax + b$$

koja je, od svih mogućih pravih, „najbliža“ tačkama $A_i(x_i, y_i)$ (slika 4). Linearni regresioni model ima smisla kada je prirodno pretpostaviti da je zavisnost y od x linearna.



Slika 4. Prava najmanjih kvadrata i odstupanja tačaka od nje (isprekidano).

2.2 Metoda najmanjih kvadrata

Šta znači „najbliža“? Za svaku tačku definišemo **odstupanje** (rezidual)

$$r_i = y_i - (ax_i + b),$$

tj. vertikalnu razliku između izmjerene vrijednosti i vrijednosti na pravoj. Odstupanja mogu biti pozitivna i negativna, pa ih ne sabiramo direktno, već sabiramo njihove kvadrate:

$$F(a, b) = r_1^2 + \cdots + r_n^2 = \sum_{i=1}^{n} \big(y_i - (ax_i + b)\big)^2.$$

F je funkcija dvije promjenljive, a i b, i tražimo njen globalni minimum. U minimumu su oba parcijalna izvoda jednaka nuli, što daje sistem dvije linearne jednačine sa dvije nepoznate, takozvane **normalne jednačine**:

$$\Big(\sum_{i=1}^{n} x_i^2\Big) a + \Big(\sum_{i=1}^{n} x_i\Big) b = \sum_{i=1}^{n} x_i y_i,$$
$$\Big(\sum_{i=1}^{n} x_i\Big) a + n\, b = \sum_{i=1}^{n} y_i.$$

Dobijeni model $y = ax + b$ služi da se procijeni veličina y za bilo koje dato x.

Primjer: prava kroz pet tačaka

Data su mjerenja $(1,2)$, $(2,3)$, $(3,5)$, $(4,4)$, $(5,6)$. Potrebne sume su: $\sum x_i = 15$, $\sum y_i = 20$, $\sum x_i^2 = 55$, $\sum x_i y_i = 69$, a $n = 5$. Normalne jednačine glase

$$55a + 15b = 69, \qquad 15a + 5b = 20.$$

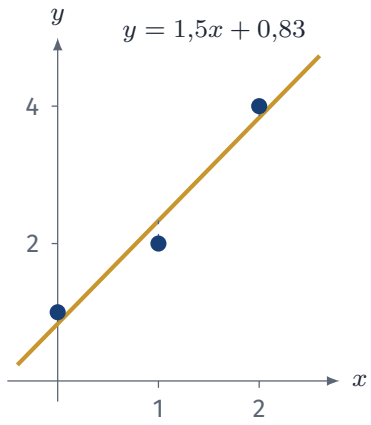
Iz druge jednačine je $b = 4 - 3a$. Uvrštavanjem u prvu: $55a + 60 - 45a = 69$, pa je $a = 0{,}9$ i $b = 1{,}3$. Prava je $y = 0{,}9x + 1{,}3$, a procjena za $x = 6$ je $y = 6{,}7$.

Normalne jednačine često se pišu u matričnom obliku:

$$\begin{bmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & n \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum x_i y_i \\ \sum y_i \end{bmatrix}.$$

Primjer: prava kroz tri tačke

Za tačke $(0,1)$, $(1,2)$, $(2,4)$ (slika 5) je $\sum x_i = 3$, $\sum y_i = 7$, $\sum x_i^2 = 5$, $\sum x_i y_i = 10$ i $n = 3$, pa sistem glasi $5a + 3b = 10$, $3a + 3b = 7$. Oduzimanjem dobijamo $2a = 3$, tj. $a = 1{,}5$, a zatim $b = (7 - 4{,}5)/3 \approx 0{,}83$. Linearna aproksimacija je $y = 1{,}5x + 0{,}83$.



Slika 5. Prava najmanjih kvadrata kroz tri tačke.

3 Trend površi

3.1 Od prave do polinoma

Posmatrajmo atribut z čije su vrijednosti izmjerene duž linije, u tačkama $x_1, \ldots, x_n$. Ako z linearno raste sa lokacijom x, izuzev malih varijacija, vrijednosti u široj oblasti mogu se aproksimirati regresionim modelom

$$z(x) = b_0 + b_1 x + \varepsilon,$$

gdje su b_0 i b_1 koeficijenti polinoma, a ε je **šum**: ima normalnu raspodjelu i nezavisan je od x. U mnogim situacijama zavisnost nije linearna, pa se koristi kvadratni model $z(x) = b_0 + b_1 x + b_2 x^2 + \varepsilon$ ili polinom višeg stepena.

> **Napomena**
>
> Povećavanjem broja sabiraka polinom se može provući kroz bilo koji skup tačaka. To nije cilj: takav model prati i šum (*preprilagođavanje*). Cilj trend površi je upravo da se šum redukuje i izdvoji opšti trend.

3.2 Trend površi u dvije dimenzije

U dvije dimenzije vrši se višestruka regresija po koordinatama x i y. Površ se opisuje polinomom

$$f(x,y) = \sum_{i+j \le p} b_{ij}\, x^i y^j,$$

gdje je p **red** trend površi. Prve tri površi su:

- $p = 0$: $f = b_0$, horizontalna ravan (površ nultog reda);
- $p = 1$: $f = b_0 + b_1 x + b_2 y$, nagnuta ravan (površ prvog reda);
- $p = 2$: $f = b_0 + b_1 x + b_2 y + b_3 x^2 + b_4 xy + b_5 y^2$, kvadratna površ.

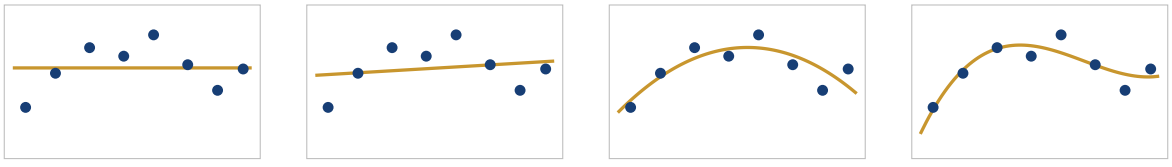
Površ trećeg reda je kubna. Broj koeficijenata površi reda p jednak je broju parova (i, j) sa $i + j \le p$, a to je

$$\frac{(p+1)(p+2)}{2},$$

dakle 1, 3, 6 i 10 za $p = 0, 1, 2, 3$. Koeficijenti se biraju tako da minimizuju zbir kvadrata odstupanja

$$\sum_{i=1}^{n} \big[z(x_i, y_i) - f(x_i, y_i)\big]^2.$$

To je standardan problem višedimenzionalne regresije i rješava se svakim statističkim paketom. Slika 6 prikazuje presjek površi različitog reda za isti uzorak.



Slika 6. Isti uzorak aproksimiran polinomima reda 0 do 3 (presjek duž jedne ose).

Globalna metoda lokalne varijacije tretira kao slučajan, nestrukturiran šum. Zato se trend površi rijetko koriste za samu interpolaciju. Mnogo češće se trend prvo izdvoji i ukloni, a ostatak (reziduali) interpolira lokalnom metodom.

4 Lokalne determinističke metode

4.1 Zašto lokalne metode

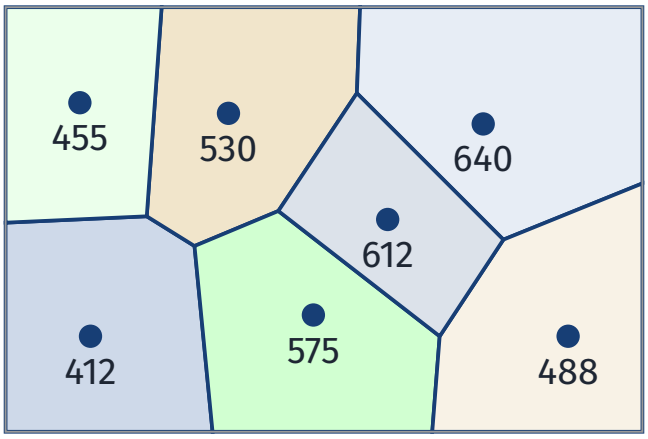
Tretirati lokalne varijacije kao šum intuitivno je pogrešno: očekujemo da vrijednost funkcije u tački bude bliska vrijednostima u njenoj neposrednoj blizini. Tu ideju formulisao je W. Tobler 1970. godine kao **prvi zakon geografije**: *sve je povezano sa svime, ali su bliže stvari povezanije od udaljenih.*

Svaka lokalna metoda zahtijeva da:

1. definišemo područje pretrage (npr. krug poluprečnika r ili k najbližih tačaka);
2. nađemo tačke sa podacima iz tog područja;
3. izaberemo matematičku funkciju kojom se računa procjena;
4. vrednujemo rezultat, tj. procijenimo grešku.

4.2 Tisenovi poligoni

Najjednostavnija lokalna metoda koristi samo *jednu*, najbližu tačku. Ravan se podijeli na **Tisenove** (Voronojeve) poligone: poligon tačke A_i sadrži sve lokacije kojima je A_i bliža od bilo koje druge tačke uzorka (slika 7). Vrijednost u cijelom poligonu jednaka je vrijednosti izmjerenoj u njegovoj tački. Ovo je varijabilna teselacija iz Lekcije 2.



Slika 7. Tisenovi poligoni za sedam mjernih tačaka.

Dobijena površ je stepenasta: vrijednost skače na granicama poligona. Metoda se koristi kada se pojava zaista mijenja skokovito ili kada treba odrediti zonu koju „opslužuje“ svaka tačka, npr. padavine po kišomjernim stanicama.

4.3 Metod inverznih distanci

Metod inverznih distanci (engl. *Inverse Distance Weighting*, IDW) računa srednju vrijednost okolnih tačaka, ali uzima u obzir njihovu udaljenost. Neka treba procijeniti $z_0 = z(x_0, y_0)$, a neka su (x_i, y_i), $1 \leq i \leq n$, bliske tačke u kojima su izmjerene vrijednosti z_i. Rastojanje tačke (x_i, y_i) od (x_0, y_0) je

$$d_i = \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2}.$$

Svakoj tački dodjeljujemo težinu $w_i = 1/d_i^p$ i računamo težinsku sredinu

$$\hat{z}_0 = \frac{\sum_{i=1}^{n} w_i z_i}{\sum_{i=1}^{n} w_i}.$$

Za $p = 1$ ovo je isto što i

$$c_i = \frac{1/d_i}{1/d_1 + \cdots + 1/d_n}, \qquad \hat{z}_0 = c_1 z_1 + \cdots + c_n z_n,$$

gdje je $c_1 + \cdots + c_n = 1$. Stvarna vrijednost je $z_0 = \hat{z}_0 + \varepsilon$, pa je $z_0 \approx \hat{z}_0$. Drugim riječima, bliže tačke više utiču na rezultat. Parametar p (u praksi najčešće 2) određuje koliko brzo uticaj opada sa rastojanjem.

Primjer: IDW

Procjenjujemo vrijednost u tački $P_0 = (2, 2)$ iz tri tačke (slika 8): $A_1(1, 2)$ sa $z_1 = 100$, $A_2(2, 4)$ sa $z_2 = 120$ i $A_3(5, 6)$ sa $z_3 = 150$. Rastojanja su $d_1 = 1$, $d_2 = 2$ i $d_3 = \sqrt{9 + 16} = 5$.

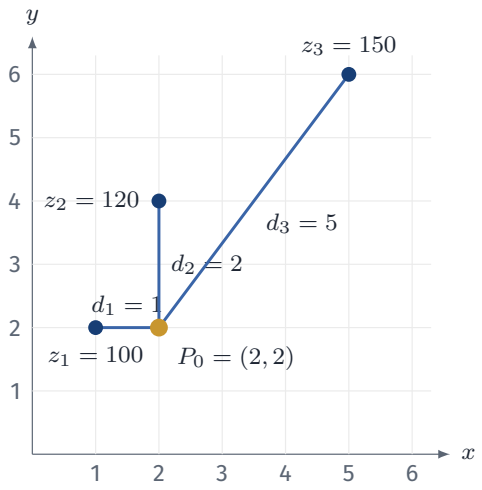
Za $p = 1$ težine su 1, $0{,}5$ i $0{,}2$, sa zbirom $1{,}7$:

$$\hat{z}_0 = \frac{1 \cdot 100 + 0{,}5 \cdot 120 + 0{,}2 \cdot 150}{1{,}7} = \frac{190}{1{,}7} \approx 111{,}8.$$

Za $p = 2$ težine su 1, $0{,}25$ i $0{,}04$, sa zbirom $1{,}29$:

$$\hat{z}_0 = \frac{100 + 30 + 6}{1{,}29} \approx 105{,}4.$$

Sa većim p procjena se približava vrijednosti najbliže tačke.



Slika 8. Procjena u tački P_0 iz tri susjedne tačke.

Svojstva IDW metode vrijedi zapamtiti: procjena je uvijek između najmanje i najveće izmjerene vrijednosti (ne može da „pogodi“ vrh koji nije izmjeren), u izmjerenim tačkama vraća tačno izmjerenu vrijednost, a oko izolovanih tačaka stvara karakteristične „pikove“.

4.4 Druge lokalne metode

- **Splajnovi** sastavljaju površ od polinoma po djelovima, glatko spojenih na granicama. Daju meke, estetski lijepe površi, ali procjena može izaći iz opsega podataka.
- **Linearna interpolacija u TIN-u**: vrijednost u tački dobija se iz tri tjemena trougla kome tačka pripada (Lekcija 2).

Sve navedene metode su determinističke: daju procjenu, ali ne i informaciju o njenoj pouzdanosti.

5 Kriging

5.1 Ideja

Kriging je tehnika interpolacije nazvana po južnoafričkom rudarskom inženjeru D. Krigeu, koji je procjenjivao sadržaj zlata u rudi; matematičku teoriju razvio je francuski matematičar G. Matheron. Osnovna razlika u odnosu na IDW je u tome kako se biraju težine: umjesto unaprijed zadate formule, težine se računaju iz *prostorne korelacije* samih podataka.

Kriging počiva na teoriji **regionalizovane promjenljive**, po kojoj se vrijednost u tački $\mathbf{x}$ sastoji od tri komponente:

$$Z(\mathbf{x}) = m(\mathbf{x}) + \varepsilon'(\mathbf{x}) + \varepsilon'',$$

gdje je $m(\mathbf{x})$ strukturna komponenta (trend), $\varepsilon'(\mathbf{x})$ slučajna, ali prostorno korelisana varijacija regionalne komponente, a ε'' nekorelisani šum sa Gausovom raspodjelom.

5.2 Pretpostavke i centriranje

Geostatistika mjerenja posmatra kao vrijednosti jedne **slučajne funkcije** $Z(\mathbf{x})$: izmjereni teren je samo jedna od mogućih realizacija. Da bi se iz jedne realizacije moglo zaključivati, pretpostavlja se **stacionarnost** (drugog reda):

- očekivanje je isto u svim tačkama: $E[Z(\mathbf{x})] = m$;
- kovarijansa dvije vrijednosti zavisi samo od njihovog rastojanja h, a ne od položaja: $\operatorname{Cov}\big(Z(\mathbf{x}), Z(\mathbf{x}+\mathbf{h})\big) = C(h)$.

Ako podaci imaju izražen trend, on se prvo ukloni (npr. trend površi iz odjeljka 3), pa se kriging primjenjuje na reziduale.

Uvodimo **centriranu** promjenljivu

$$Y(\mathbf{x}) = Z(\mathbf{x}) - m, \qquad E[Y(\mathbf{x})] = 0, \qquad E\big[Y(\mathbf{x})\,Y(\mathbf{x}+\mathbf{h})\big] = C(h).$$

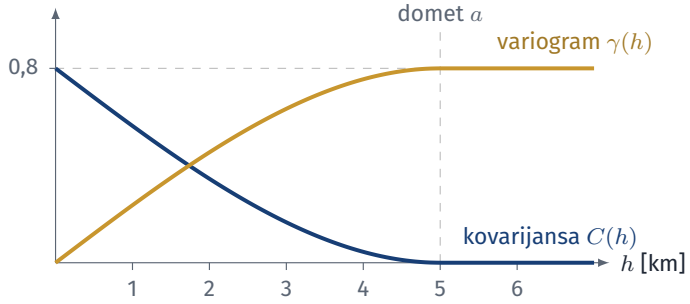
Jednostavni kriging procjenjuje Y, a na kraju dodaje m. Kao što ćemo vidjeti, upravo centriranje garantuje da je procjena nepristrasna.

5.3 Kovarijansa i variogram

Stepen korelacije vrijednosti u dvije tačke opada sa njihovim rastojanjem h. To opisujemo **kovarijansnom funkcijom** $C(h)$. Često se koristi *sferni model*: funkcija $1 - 1{,}5h + 0{,}5h^3$ opada od 1 za $h = 0$ do 0 za $h = 1$. Ako rastojanje mjerimo u metrima i želimo da korelacija nestane na 5000 m, uzimamo

$$C(h) = \begin{cases} 0{,}8\left(1 - 1{,}5\dfrac{h}{5000} + 0{,}5\left(\dfrac{h}{5000}\right)^3\right), & 0 \le h \le 5000, \\ 0, & h > 5000. \end{cases}$$

Rastojanje $a = 5000$ m na kome korelacija nestaje zove se **domet**. Umjesto kovarijanse geostatističari najčešće crtaju **variogram** $\gamma(h) = C(0) - C(h)$, koji mjeri koliko se vrijednosti *razlikuju* na rastojanju h (slika 9). U praksi se variogram procjenjuje iz podataka: za parove tačaka na sličnom rastojanju računa se polovina srednjeg kvadrata razlike, pa se kroz dobijene tačke provuče model (sferni, eksponencijalni, Gausov).



Slika 9. Sferni model kovarijanse $C(h)$ i odgovarajući variogram $\gamma(h)$ sa dometom 5 km.

5.4 Empirijski variogram

Funkcija $C(h)$ nije unaprijed poznata, već se procjenjuje iz podataka. Za stacionarnu funkciju je $E\big[(Z(\mathbf{x}) - Z(\mathbf{x}+\mathbf{h}))^2\big] = 2C(0) - 2C(h) = 2\gamma(h)$, pa se variogram prirodno procjenjuje kao polovina srednjeg kvadrata razlike parova tačaka na rastojanju h:

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \sum_{d_{ij} \approx h} (z_i - z_j)^2,$$

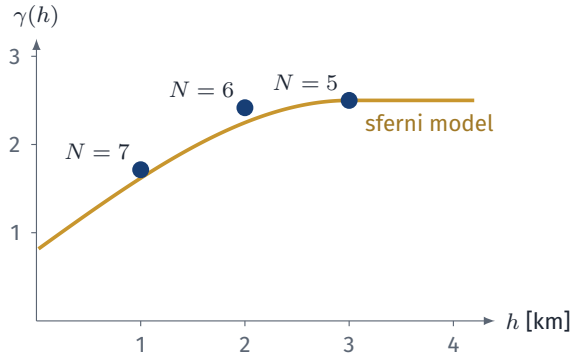
gdje je $N(h)$ broj parova čije je rastojanje približno h (parovi se grupišu u klase rastojanja). Ovo je **empirijski variogram**.

Primjer: empirijski variogram

Duž profila je mjereno na svaki kilometar: $z = 4, 6, 5, 7, 4, 3, 5, 6$.

- $h = 1$: sedam parova, razlike $-2, 1, -2, 3, 1, -2, -1$, zbir kvadrata 24, pa $\hat{\gamma}(1) = 24/14 \approx 1{,}71$;
- $h = 2$: šest parova, razlike $-1, -1, 1, 4, -1, -3$, zbir kvadrata 29, pa $\hat{\gamma}(2) = 29/12 \approx 2{,}42$;
- $h = 3$: pet parova, razlike $-3, 2, 2, 2, -2$, zbir kvadrata 25, pa $\hat{\gamma}(3) = 25/10 = 2{,}5$.

Variogram raste i oko $h = 3$ km se izravnava (slika 10).



Slika 10. Empirijski variogram (tačke) i sferni model provučen kroz njih ($c_0 = 0{,}8$, plato 2,5, domet 3 km).

5.5 Modeli variograma

Kroz tačke empirijskog variograma provlači se *dozvoljeni* model: ne može se uzeti bilo koja kriva, jer matrica A u sistemu krigovanja mora ostati pozitivno definitna. Model se opisuje sa tri parametra (slika 11):

- **efekat grumena** c_0 (*nugget*): skok variograma u nuli, posljedica grešaka mjerenja i varijacija na rastojanjima manjim od razmaka tačaka (ime potiče od grumenja zlata);
- **plato** $c_0 + c$ (*sill*): vrijednost kojoj variogram teži; jednak je varijansi $C(0)$;
- **domet** a (*range*): rastojanje na kome variogram dostiže plato.

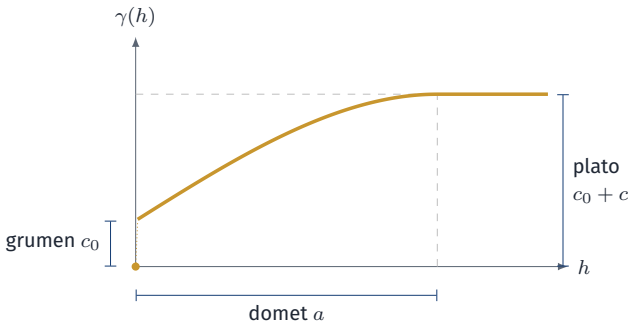
Najčešći modeli (za $h > 0$) su:

$$\text{sferni:}\quad \gamma(h) = c_0 + c\left(1{,}5\frac{h}{a} - 0{,}5\frac{h^3}{a^3}\right),\ h \le a; \qquad \gamma(h) = c_0 + c,\ h > a,$$

$$\text{eksponencijalni:}\quad \gamma(h) = c_0 + c\left(1 - e^{-3h/a}\right),$$

$$\text{Gausov:}\quad \gamma(h) = c_0 + c\left(1 - e^{-3h^2/a^2}\right).$$

Eksponencijalni i Gausov model dostižu plato samo asimptotski; a je tada *praktični* domet, na kome je dostignuto 95 % platoa. Gausov model opisuje vrlo glatke pojave (npr. teren bez naglih prelaza), a eksponencijalni grublje.



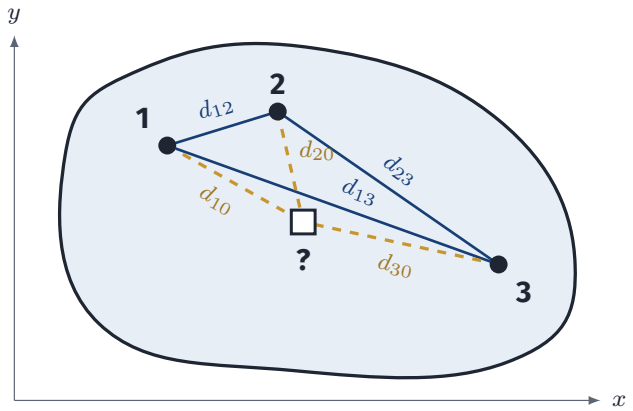
Slika 11. Parametri variograma: efekat grumena, plato i domet.

5.6 Postavka problema

Tipična situacija prikazana je na slici 12: u oblasti su poznate vrijednosti u tačkama 1, 2 i 3, a tražimo vrijednost u tački označenoj sa „?“. Kriging za to koristi dvije vrste rastojanja:

- rastojanja d_{i0} od mjerenja do nepoznate tačke (isprekidano); iz njih se dobija vektor $\mathbf{b}$, $b_i = C(d_{i0})$;
- rastojanja d_{ij} *između* samih mjerenja (puno); iz njih se dobija matrica A, $a_{ij} = C(d_{ij})$.

IDW koristi samo prvu vrstu rastojanja. Druga vrsta omogućava krigovanju da prepozna redundantna mjerenja.



Slika 12. Tri mjerenja i tačka u kojoj procjenjujemo vrijednost. Isprekidano: rastojanja do nepoznate tačke; puno: rastojanja između mjerenja.

Primjer: tri tačke

Neka su tačke $1 = (1500, 2700)$, $2 = (2800, 3100)$, $3 = (5400, 1300)$, a nepoznata tačka $(3100, 1800)$ (u metrima), sa sfernim modelom $C(0) = 0{,}8$ i dometom 5000 m. Tada je

$$A = \begin{bmatrix} 0{,}800 & 0{,}482 & 0{,}033 \\ 0{,}482 & 0{,}800 & 0{,}142 \\ 0{,}033 & 0{,}142 & 0{,}800 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 0{,}379 \\ 0{,}487 \\ 0{,}277 \end{bmatrix},$$

a rješenje sistema $A\mathbf{c} = \mathbf{b}$ je $\mathbf{c} \approx (0{,}20;\ 0{,}45;\ 0{,}26)$, uz $\sigma^2_{SK} \approx 0{,}44$. Normalizovane težine IDW ($p = 1$) su $(0{,}32;\ 0{,}44;\ 0{,}25)$. Najveća razlika je kod tačke 1: ona je blizu tačke 2 ($d_{12} = 1360$ m), pa nosi djelimično istu informaciju, i kriging joj smanjuje težinu. Zbir težina krigovanja je 0,90; preostalih 0,10 jednostavni kriging daje srednjoj vrijednosti m.

5.7 Kriging kao najbolji linearni nepristrasni estimator

Pokažimo zašto su težine krigovanja baš rješenje sistema $A\mathbf{c} = \mathbf{b}$. Neka su u tačkama $A_1, \dots, A_n$ poznate vrijednosti, a procjenjujemo vrijednost u A_0. Označimo $Y_i = Y(A_i)$, $Y_0 = Y(A_0)$, $a_{ij} = C(d_{ij})$ i $b_i = C(d_{i0})$.

1. Linearnost. Procjenu tražimo kao linearnu kombinaciju centriranih mjerenja:

$$\hat{Y}_0 = \sum_{i=1}^{n} c_i Y_i, \qquad \hat{Z}_0 = m + \sum_{i=1}^{n} c_i (Z_i - m).$$

Greška procjene je $e = \hat{Y}_0 - Y_0 = \hat{Z}_0 - Z_0$.

2. Nepristrasnost. Kako je $E[Y_i] = 0$ za svako i,

$$E[e] = \sum_{i=1}^{n} c_i E[Y_i] - E[Y_0] = 0.$$

Procjena je, dakle, nepristrasna *za bilo koji izbor težina*: u prosjeku ne precjenjuje niti potcjenjuje. To je posljedica centriranja. Ali nepristrasnih linearnih procjena ima beskonačno mnogo (sve težine), pa nam treba kriterijum za izbor.

3. Varijansa greške. Kako je $E[e] = 0$, varijansa greške jednaka je srednjoj kvadratnoj grešci:

$$\sigma^2(\mathbf{c}) = E[e^2] = E\Big[\Big(\sum_i c_i Y_i - Y_0\Big)^2\Big] = \sum_i \sum_j c_i c_j E[Y_i Y_j] - 2\sum_i c_i E[Y_i Y_0] + E[Y_0^2],$$

odnosno, u matričnom obliku,

$$\sigma^2(\mathbf{c}) = \mathbf{c}^{\mathsf{T}} A\, \mathbf{c} - 2\, \mathbf{c}^{\mathsf{T}} \mathbf{b} + C(0).$$

Ovo je kvadratna funkcija težina. Važno je primijetiti da zavisi samo od položaja tačaka i od kovarijanse, a ne od izmjerenih vrijednosti; zato se greška može izračunati i prije mjerenja, npr. pri planiranju mreže stanica.

4. Minimum. U minimumu su svi parcijalni izvodi jednaki nuli:

$$\frac{\partial \sigma^2}{\partial c_i} = 2\sum_j a_{ij}c_j - 2b_i = 0, \quad i = 1, \ldots, n \qquad \Longleftrightarrow \qquad A\mathbf{c} = \mathbf{b}.$$

To je upravo sistem jednostavnog krigovanja. Uvrštavanjem rješenja $\mathbf{c}^*$ dobijamo **varijansu krigovanja**:

$$\sigma^2_{SK} = \sigma^2(\mathbf{c}^*) = C(0) - \mathbf{c}^{*\mathsf{T}}\mathbf{b} = C(0) - \sum_{i=1}^{n} c_i^* b_i.$$

5. Ovo je zaista najbolja procjena. Neka su $\mathbf{c} = \mathbf{c}^* + \boldsymbol{\delta}$ bilo koje druge težine. Razvojem kvadratne forme dobijamo

$$\sigma^2(\mathbf{c}^* + \boldsymbol{\delta}) = \sigma^2(\mathbf{c}^*) + 2\,\boldsymbol{\delta}^{\mathsf{T}}\big(A\mathbf{c}^* - \mathbf{b}\big) + \boldsymbol{\delta}^{\mathsf{T}} A\,\boldsymbol{\delta} = \sigma^2(\mathbf{c}^*) + \boldsymbol{\delta}^{\mathsf{T}} A\,\boldsymbol{\delta},$$

jer je $A\mathbf{c}^* = \mathbf{b}$. Matrica A je kovarijansna matrica, pa je $\boldsymbol{\delta}^{\mathsf{T}} A \boldsymbol{\delta} = \operatorname{Var}\big(\sum_i \delta_i Y_i\big) \geq 0$. Dakle, svaka druga linearna procjena ima grešku veću ili jednaku grešci krigovanja. Ako su tačke različite i model dozvoljen, A je pozitivno definitna, pa je nejednakost stroga za $\boldsymbol{\delta} \neq 0$ i rješenje je jedinstveno.

> **Ključno**
>
> Kriging je **najbolji linearni nepristrasni estimator** (engl. *Best Linear Unbiased Estimator*, BLUE):
>
> - **linearan**, jer je procjena linearna kombinacija mjerenja;
> - **nepristrasan**, jer je zbog centriranja $E[\hat{Z}_0 - Z_0] = 0$;
> - **najbolji**, jer među svim takvim procjenama ima najmanju varijansu greške.

5.8 Jednostavni kriging

Neka je u ravni data veličina $z = z(x, y)$, npr. elevacija terena ili koncentracija zlata, i neka je izmjerena u N tačaka. Sa m označimo srednju vrijednost veličine z po svih N tačaka. Posmatrajmo tačku $A_0(x_0, y_0)$ u kojoj nije mjereno; tražimo procjenu $\hat{z}_0$ za $z_0 = z(x_0, y_0)$.

1. Od N tačaka izaberemo n najbližih tački A_0 i označimo ih $A_i(x_i, y_i)$, sa vrijednostima z_i, $1 \leq i \leq n$.
2. Formiramo matricu $A = [a_{ij}]$, gdje je $a_{ij} = C(d_{ij})$, a d_{ij} rastojanje između A_i i A_j. Ona izražava korelaciju među izabranim tačkama.
3. Formiramo vektor $\mathbf{b} = [b_i]$, gdje je $b_i = C(d_{i0})$: povezanost tačke A_i i tačke A_0.
4. Rješavamo sistem linearnih jednačina $A\mathbf{c} = \mathbf{b}$ po vektoru nepoznatih $\mathbf{c} = [c_i]$.
5. Procjenu računamo po formuli

$$\hat{z}_0 = m + c_1(z_1 - m) + \cdots + c_n(z_n - m).$$

Primjer: kriging sa dvije tačke

Tačke leže na pravoj (slika 14): $A_1(1000, 0)$ sa $z_1 = 800$, $A_2(4000, 0)$ sa $z_2 = 900$; procjenjujemo vrijednost u $A_0(2500, 0)$. Srednja vrijednost cijelog uzorka je $m = 1000$, a kovarijansa je sferni model sa dometom 5000 m.

- $a_{11} = a_{22} = C(0) = 0{,}8$;
- $a_{12} = C(3000) = 0{,}8\,(1 - 0{,}9 + 0{,}108) = 0{,}8 \cdot 0{,}208 \approx 0{,}17$;
- $b_1 = b_2 = C(1500) = 0{,}8\,(1 - 0{,}45 + 0{,}0135) = 0{,}8 \cdot 0{,}5635 \approx 0{,}45$.

Sistem jednačina je

$$0{,}8c_1 + 0{,}17c_2 = 0{,}45, \qquad 0{,}17c_1 + 0{,}8c_2 = 0{,}45,$$

a zbog simetrije $c_1 = c_2 = 0{,}45/0{,}97 \approx 0{,}46$. Procjena je

$$\hat{z}_0 = 1000 + 0{,}46\,(800 - 1000) + 0{,}46\,(900 - 1000) \approx 860.$$

Primijetite da procjena nije prosta sredina 850: kriging je „povukao“ procjenu prema srednjoj vrijednosti $m = 1000$, jer dvije tačke na rastojanju 1500 m nisu potpuno korelisane sa A_0. Varijansa krigovanja je

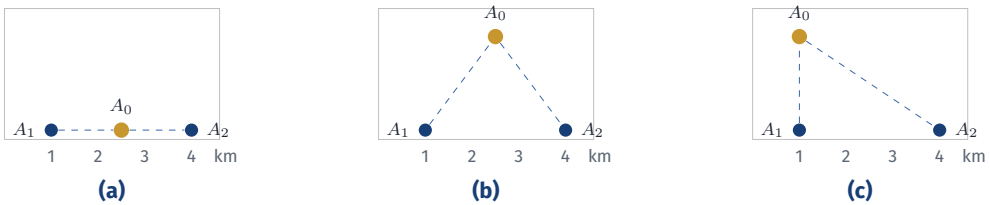
$$\sigma^2_{SK} = 0{,}8 - (0{,}4665 \cdot 0{,}4508 + 0{,}4665 \cdot 0{,}4508) \approx 0{,}379.$$

Primjer: tačka van prave

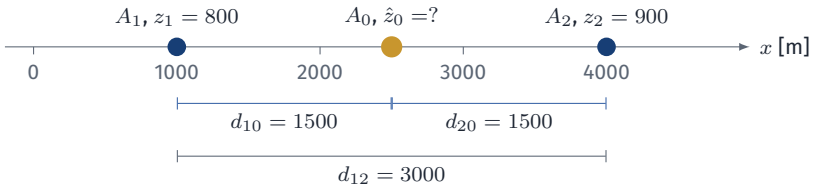
Ponovimo račun za dva položaja tačke A_0 van prave kroz A_1 i A_2 (slika 13). Matrica A se ne mijenja, jer zavisi samo od tačaka uzorka; mijenja se vektor $\mathbf{b}$.

- (b) $A_0 = (2500, 2000)$: $d_{10} = d_{20} = 2500$, $b_1 = b_2 = C(2500) = 0{,}25$, pa je $c_1 = c_2 = 0{,}25/0{,}966 \approx 0{,}26$ i $\hat{z}_0 \approx 1000 - 0{,}26 \cdot 300 \approx 922$.
- (c) $A_0 = (1000, 2000)$: $d_{10} = 2000$, $d_{20} = \sqrt{3000^2 + 2000^2} \approx 3606$, $b_1 = C(2000) \approx 0{,}346$, $b_2 = C(3606) \approx 0{,}085$. Rješenje sistema je $c_1 \approx 0{,}43$, $c_2 \approx 0{,}02$, pa je $\hat{z}_0 \approx 1000 - 0{,}43 \cdot 200 - 0{,}02 \cdot 100 \approx 913$.

Što je A_0 dalje od uzorka, procjena je bliža srednjoj vrijednosti m; kada je jedna tačka mnogo bliža, ona gotovo sama određuje procjenu. Varijanse krigovanja su 0,671 za (b) i 0,651 za (c): obje su veće nego u (a), jer je A_0 dalje od tačaka uzorka.



Slika 13. Tri položaja tačke A_0 u odnosu na tačke uzorka A_1 i A_2.



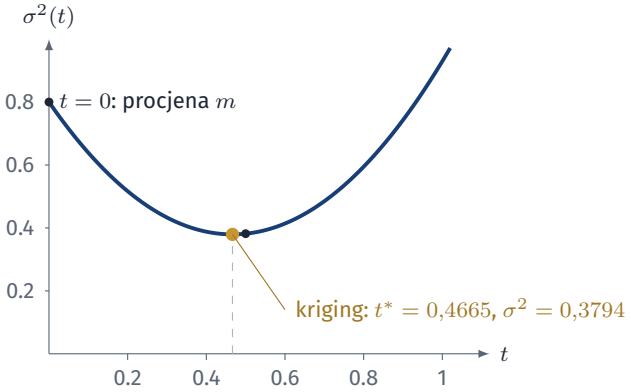
Slika 14. Podaci za primjer krigovanja.

5.9 Demonstracija: kriging je najbolji

Na formuli. U primjeru (a) su zbog simetrije sve razumne težine jednake, $c_1 = c_2 = t$. Varijansa greške je tada funkcija jedne promjenljive:

$$\sigma^2(t) = 0{,}8 - 4 \cdot 0{,}4508\, t + 2\,(0{,}8 + 0{,}1664)\, t^2 = 0{,}8 - 1{,}803\, t + 1{,}933\, t^2.$$

To je parabola sa minimumom u $t^* = 1{,}803/(2 \cdot 1{,}933) \approx 0{,}4665$, a to je upravo težina krigovanja (slika 15). Za $t = 0$ (procjena je samo m) greška je 0,8, za prostu sredinu ($t = 0{,}5$) 0,382, a za kriging 0,379. Sve ove procjene su nepristrasne, ali najmanju grešku ima kriging. Razlika u odnosu na prostu sredinu je ovdje mala, jer su obje tačke jednako udaljene; u nesimetričnom slučaju razlika je mnogo veća.



Slika 15. Varijansa greške kao funkcija zajedničke težine t u primjeru (a).

Simulacijom. Tvrdnje o očekivanju i varijansi mogu se provjeriti i eksperimentom. Za tačku (c), $A_0 = (1000, 2000)$, generisali smo 200 000 nezavisnih realizacija trojke (Y_1, Y_2, Y_0) sa kovarijansama $C(d_{ij})$ (normalna raspodjela; uzorak se dobija iz nezavisnih standardnih normalnih brojeva množenjem faktorom Čoleskog kovarijansne matrice). Za svaku realizaciju izračunali smo grešku $e = c_1 Y_1 + c_2 Y_2 - Y_0$ za više izbora težina. Sve procjene su u istom obliku $m + c_1(z_1 - m) + c_2(z_2 - m)$, pa su sve nepristrasne.

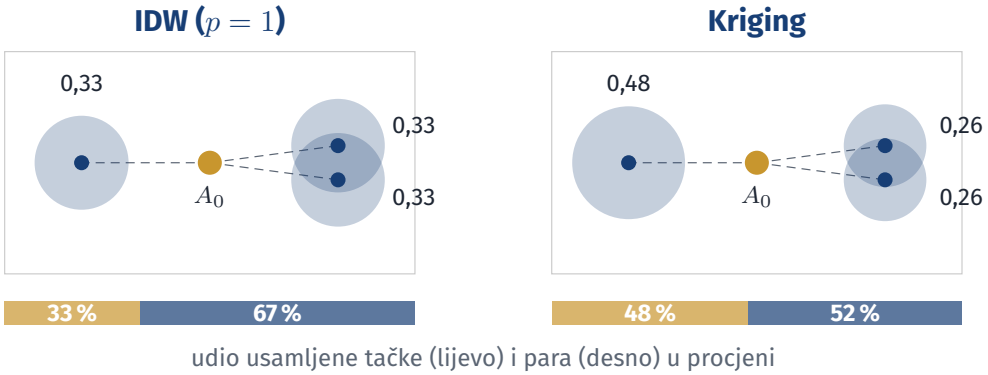
Procjena	c_1	c_2	srednja greška	varijansa (sim.)	varijansa (formula)
kriging	0,429	0,017	$-0{,}0003$	**0,650**	**0,651**
Tisen (najbliža tačka)	1	0	$-0{,}0005$	0,906	0,909
IDW, $p = 1$	0,643	0,357	$-0{,}0006$	0,801	0,804
IDW, $p = 2$	0,765	0,235	$-0{,}0006$	0,800	0,804
prosta sredina	0,5	0,5	$-0{,}0006$	0,850	0,853
samo m	0	0	$0{,}0000$	0,801	0,800

Tabela 1. Simulacija sa 200 000 realizacija za tačku (c). Formula: $\sigma^2(\mathbf{c}) = \mathbf{c}^\mathsf{T} A\mathbf{c} - 2\mathbf{c}^\mathsf{T}\mathbf{b} + C(0)$.

Rezultati (tabela 1) potvrđuju sve tri tvrdnje:

- srednja greška je za sve procjene praktično nula (razlike su reda 10^{-4}, koliko se očekuje od slučajnog uzorka): sve su *nepristrasne*;
- simulirane varijanse slažu se sa formulom $\sigma^2(\mathbf{c})$;
- kriging ima *najmanju* varijansu. Zanimljivo je da IDW i najbliža tačka ovdje nisu bolji od same srednje vrijednosti m: tačka A_0 je daleko od uzorka, a te metode svejedno daju veliku težinu mjerenjima. Kriging „zna“ koliko je korelacija slaba, pa drugu tačku gotovo zanemaruje, a prvu uzima sa težinom 0,43.

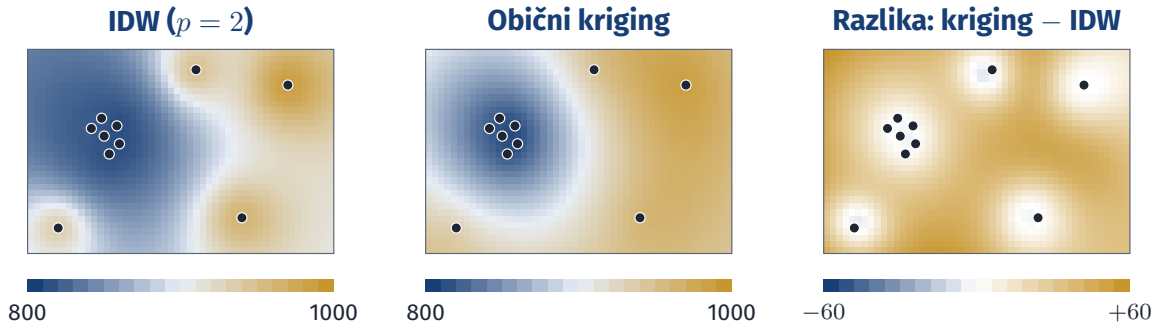
Grupisane tačke. Najvažnija praktična razlika u odnosu na IDW vidi se kada su mjerenja grupisana. Na slici 16 sve tri tačke su približno 1500 m od A_0, ali su dvije desne, na $(1500, \pm 200)$, blizu jedna drugoj. IDW gleda samo rastojanje do A_0, pa sve tri dobijaju težinu 0,33, a par zajedno dvije trećine uticaja, samo zato što je na toj strani mjereno dva puta. Kriging (obični, $\sum \lambda_i = 1$) gleda i rastojanja *između* mjernih tačaka, preko matrice A: dvije bliske tačke su jako korelisane i nose skoro istu informaciju, pa dijele težinu (0,26 i 0,26), a usamljena tačka dobija 0,48. Lijeva i desna strana su tako gotovo ravnopravne. Ova pojava zove se **deklasterovanje** (*declustering*). Srodna je pojava **efekat zaklanjanja** (*screening*): tačka koja se nalazi „iza“ bliže tačke, gledano iz A_0, dobija vrlo malu težinu.



Slika 16. Težine IDW i krigovanja za par bliskih tačaka i jednu usamljenu tačku. Površina kruga srazmjerna je težini.

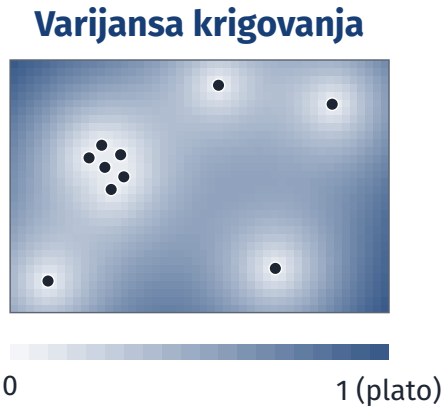
U ravni je razlika još uočljivija (slika 17). Šest bliskih mjerenja niskih vrijednosti nalazi se u

lijevom dijelu mape, a četiri mjerenja viših vrijednosti su razbacana. IDW ($p = 2$) grupu „broji“ šest puta, pa se niske vrijednosti šire daleko od nje, a oko usamljenih tačaka nastaju pikovi. Obični kriging (sferni variogram, domet 4 km) grupu tretira kao skup redundantnih mjerenja. U tački $(3;\ 2)$ ukupna težina grupe je 0,74 kod IDW, a 0,45 kod krigovanja, pa su procjene 849 i 891. Mapa razlike pokazuje da se metode najviše razilaze *između* grupe i usamljenih tačaka (do 61 jedinice), a da se gotovo poklapaju u samim mjernim tačkama i u neposrednoj blizini grupe.



Slika 17. Ista mjerenja interpolirana metodom IDW i običnim krigovanjem, i njihova razlika. Tačke su mjerna mjesta.

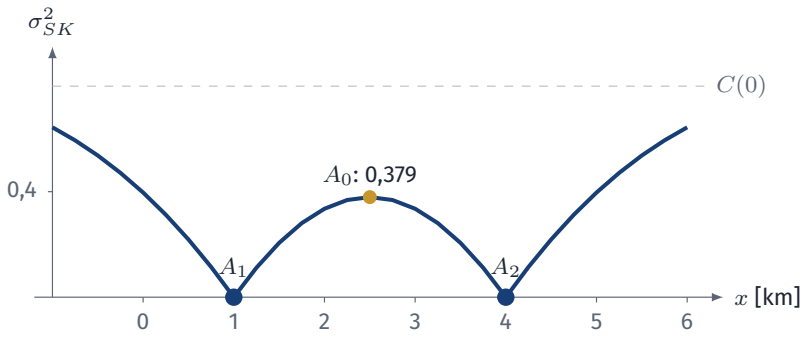
Za iste podatke mapa varijanse krigovanja (slika 18) pokazuje da je greška mala oko mjerenja i raste prema platou daleko od njih. Šest tačaka u grupi smanjuje grešku tek malo više nego što bi to učinila jedna, pa bi novo mjerenje najviše koristilo u desnom dijelu mape.



Slika 18. Varijansa običnog krigovanja za podatke sa slike 17.

5.10 Varijansa krigovanja

Varijansa krigovanja može se izračunati u svakoj tački, pa se uz mapu procjene dobija i *mapa pouzdanosti*. Slika 19 prikazuje σ^2_{SK} duž prave kroz A_1 i A_2: u mjerenim tačkama je nula (kriging bez efekta grumena je *egzaktan* interpolator, tj. vraća izmjerenu vrijednost), između njih raste, a daleko od uzorka teži platou $C(0) = 0{,}8$, tj. neizvjesnosti kakvu imamo bez ijednog mjerenja. Mapa varijanse pokazuje gdje je procjena nepouzdana i gdje bi novo mjerenje donijelo najviše.



Slika 19. Varijansa jednostavnog krigovanja duž prave kroz A_1 i A_2.

5.11 Obični kriging

Jednostavni kriging pretpostavlja da je srednja vrijednost m poznata. U praksi to obično nije slučaj, pa se koristi **obični kriging** (*ordinary kriging*). Procjena se traži direktno kao $\hat{Z}_0 = \sum_i \lambda_i Z_i$, a tada je

$$E[\hat{Z}_0 - Z_0] = \sum_i \lambda_i m - m = m\Big(\sum_i \lambda_i - 1\Big),$$

pa je procjena nepristrasna za svako m *ako i samo ako* je $\sum_i \lambda_i = 1$. Varijansa greške ima isti oblik kao ranije, $\boldsymbol{\lambda}^\mathsf{T} A \boldsymbol{\lambda} - 2\boldsymbol{\lambda}^\mathsf{T}\mathbf{b} + C(0)$, ali sada se minimizuje uz ograničenje. Uz Lagranžov množilac μ minimizujemo

$$L(\boldsymbol{\lambda}, \mu) = \boldsymbol{\lambda}^\mathsf{T} A \boldsymbol{\lambda} - 2\boldsymbol{\lambda}^\mathsf{T}\mathbf{b} + C(0) + 2\mu\Big(\sum_i \lambda_i - 1\Big),$$

i izjednačavanjem izvoda sa nulom dobijamo sistem

$$\begin{bmatrix} A & \mathbf{1} \\ \mathbf{1}^\mathsf{T} & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{\lambda} \\ \mu \end{bmatrix} = \begin{bmatrix} \mathbf{b} \\ 1 \end{bmatrix}, \qquad \sigma^2_{OK} = C(0) - \boldsymbol{\lambda}^\mathsf{T}\mathbf{b} - \mu.$$

Argument da je rješenje najbolje isti je kao kod jednostavnog krigovanja, samo što se porede težine sa zbirom 1.

> **Primjer: obični kriging**
>
> U primjeru (a) zbog simetrije i uslova $\lambda_1 + \lambda_2 = 1$ dobijamo $\lambda_1 = \lambda_2 = 0{,}5$, a iz prve jednačine $\mu = 0{,}4508 - 0{,}5(0{,}8 + 0{,}1664) \approx -0{,}032$. Procjena je prosta sredina $\hat{z}_0 = 850$, a $\sigma^2_{OK} = 0{,}8 - 0{,}4508 + 0{,}032 \approx 0{,}382$. U primjeru (c) rješenje je $\lambda_1 \approx 0{,}71$, $\lambda_2 \approx 0{,}29$, $\mu \approx -0{,}268$, pa je $\hat{z}_0 \approx 829$ i $\sigma^2_{OK} \approx 0{,}799$.

Obični kriging ima veću grešku od jednostavnog (0,382 naspram 0,379 i 0,799 naspram 0,651): to je cijena toga što ne poznajemo m. Zauzvrat je otporniji na lokalne promjene srednje vrijednosti, pa se u praksi najčešće koristi. **Univerzalni kriging** ide korak dalje: umjesto konstantne srednje vrijednosti procjenjuje trend $m(\mathbf{x})$, npr. ravan $b_0 + b_1 x + b_2 y$.

5.12 Kriging u praksi

Postupak u GIS softveru (SAGA, R `gstat`, ArcGIS Geostatistical Analyst) ima ove korake:

1. **istraživanje podataka**: histogram, izuzeci, postojanje trenda;
2. **empirijski variogram**: parovi tačaka po klasama rastojanja;
3. **izbor modela**: tip (sferni, eksponencijalni, Gausov) i parametri c_0, plato, domet;
4. **unakrsna provjera** (*cross-validation*): svaka mjerena tačka se privremeno izbaci i procijeni iz ostalih; prosječna greška treba da bude približno nula, a srednji kvadrat greške blizak prosječnoj procijenjenoj varijansi krigovanja;
5. **kriging**: sistem se rješava za svaku ćeliju rastera, obično sa ograničenim brojem najbližih tačaka;
6. **dvije mape**: mapa procjene i mapa varijanse (ili standardne greške).

5.13 Poređenje metoda

	Trend površi	Tisenovi poligoni	IDW	Kriging
Vrsta	globalna	lokalna	lokalna	lokalna, geostatistička
Izgled površi	glatka	stepenasta	„pikovi“ oko tačaka	glatka
Prolazi kroz tačke	ne	da	da	da (bez šuma)
Greška procjene	ne	ne	ne	da
Složenost	mala	vrlo mala	mala	velika (variogram)

Tabela 2. Poređenje metoda interpolacije.

> **Napomena**
>
> U QGIS-u se IDW i TIN interpolacija nalaze među alatima za obradu (*Processing*), GDAL nudi alat `gdal_grid`, a kriging nude SAGA GIS i R paket `gstat`. Prije interpolacije uvijek provjerite da su podaci u projektovanom koordinatnom sistemu (Lekcija 4): rastojanja u stepenima nemaju smisla za IDW ni za variogram.

Rezime

Ključno

- *Interpolacija* procjenjuje vrijednost u tački iz mjerenja u okolnim tačkama istog regiona; van oblasti mjerenja govorimo o ekstrapolaciji.
- Globalne metode (trend površi) koriste sve podatke i hvataju opšti trend; lokalne koriste samo susjedne tačke.
- Prava $y = ax + b$ i trend površi određuju se *metodom najmanjih kvadrata*; površ reda p ima $(p+1)(p+2)/2$ koeficijenata.
- Tisenovi poligoni koriste najbližu tačku; IDW računa težinsku sredinu sa težinama $1/d^p$.
- Kriging računa težine iz kovarijanse (variograma) podataka rješavanjem sistema $A\mathbf{c} = \mathbf{b}$ i daje i procjenu greške.
- Variogram se procjenjuje iz podataka (empirijski variogram) i opisuje modelom sa efektom grumena, platoom i dometom.
- Kriging je *najbolji linearni nepristrasni estimator*: zbog centriranja je nepristrasan, a težine minimizuju varijansu greške $\sigma^2(\mathbf{c}) = \mathbf{c}^\mathsf{T} A\mathbf{c} - 2\mathbf{c}^\mathsf{T}\mathbf{b} + C(0)$.
- Obični kriging ne zahtijeva poznatu srednju vrijednost: uslov $\sum \lambda_i = 1$ i Lagranžov množilac.

Pitanja za provjeru znanja

1. Šta je interpolacija, a šta ekstrapolacija? Zašto je ekstrapolacija nepouzdanija?
2. Navedite tri situacije u kojima je potrebna interpolacija.
3. Koja je razlika između globalnih i lokalnih metoda? Navedite po dva primjera.
4. Šta minimizuje metoda najmanjih kvadrata? Zašto se sabiraju kvadrati odstupanja?
5. Napišite normalne jednačine za pravu $y = ax + b$.
6. Šta je red trend površi? Koliko koeficijenata ima kvadratna površ?
7. Zašto se trend površi rijetko koriste za direktnu interpolaciju?
8. Šta kaže prvi zakon geografije i kako je povezan sa lokalnim metodama?
9. Kako nastaju Tisenovi poligoni i kakvu površ daju?
10. Kako parametar p utiče na rezultat IDW metode?
11. Može li IDW procjena biti veća od najveće izmjerene vrijednosti? Obrazložite.
12. Od kojih komponenti se sastoji regionalizovana promjenljiva?
13. Šta je variogram i šta je domet?

14. Koju prednost kriging ima u odnosu na determinističke metode?
15. Šta znači stacionarnost i zašto je potrebna?
16. Kako se računa empirijski variogram? Šta su efekat grumena, plato i domet?
17. Zašto je procjena jednostavnog krigovanja nepristrasna za bilo koje težine?
18. Izvedite varijansu greške $\sigma^2(\mathbf{c})$ i iz nje sistem $A\mathbf{c} = \mathbf{b}$.
19. Pokažite da nijedna druga linearna procjena nema manju varijansu greške od krigovanja.
20. Koliko je varijansa krigovanja u mjerenoj tački, a koliko daleko od svih tačaka?
21. Po čemu se obični kriging razlikuje od jednostavnog? Odakle uslov $\sum \lambda_i = 1$?

Zadaci za vježbu

1. **Prava najmanjih kvadrata.** Za mjerenja $(0,1)$, $(1,3)$, $(2,4)$, $(3,4)$ odredite pravu $y = ax + b$ metodom najmanjih kvadrata i procijenite y za $x = 4$.
2. **IDW.** U tački $P_0 = (0,0)$ procijenite vrijednost iz tačaka $A_1(3,0)$ sa $z_1 = 10$, $A_2(0,4)$ sa $z_2 = 20$ i $A_3(-6,8)$ sa $z_3 = 40$, za $p = 1$ i za $p = 2$.
3. **Trend površi.** Koliko koeficijenata ima trend površ četvrtog reda? Imamo 10 mjernih tačaka. Šta se dešava ako kroz njih provučemo površ trećeg reda?
4. **Kriging sa jednom tačkom.** Uz isti model kovarijanse kao u primjeru ($C(0) = 0{,}8$, domet 5000 m) i $m = 1000$, procijenite z_0 iz jedne tačke sa $z_1 = 800$ na rastojanju (a) 2500 m i (b) 6000 m.
5. **Kriging je najbolji.** Za jednu tačku na rastojanju 2500 m iz prethodnog zadatka napišite varijansu greške $\sigma^2(c)$ kao funkciju težine c, nađite njen minimum i izračunajte varijansu za $c = 0$, $c = 0{,}3125$ i $c = 1$.
6. **Empirijski variogram.** Duž profila mjereno je na svaki kilometar: $z = 2, 3, 5, 4, 6$. Izračunajte $\hat{\gamma}(1)$ i $\hat{\gamma}(2)$.

Rješenja

1. $n = 4$, $\sum x_i = 6$, $\sum y_i = 12$, $\sum x_i^2 = 14$, $\sum x_i y_i = 23$. Sistem: $14a + 6b = 23$, $6a + 4b = 12$. Iz druge je $b = 3 - 1{,}5a$, pa $14a + 18 - 9a = 23$, tj. $a = 1$ i $b = 1{,}5$. Prava je $y = x + 1{,}5$, a za $x = 4$ dobijamo $y = 5{,}5$.
2. Rastojanja su $d_1 = 3$, $d_2 = 4$, $d_3 = \sqrt{36 + 64} = 10$. Za $p = 1$: težine $1/3$, $1/4$, $1/10$ (zbir $0{,}6833$), pa $\hat{z}_0 = (10/3 + 20/4 + 40/10)/0{,}6833 = 12{,}333/0{,}6833 \approx 18{,}0$. Za $p = 2$: težine $1/9$, $1/16$, $1/100$ (zbir $0{,}1836$), pa $\hat{z}_0 = (1{,}111 + 1{,}25 + 0{,}4)/0{,}1836 \approx 15{,}0$.
3. $(4 + 1)(4 + 2)/2 = 15$ koeficijenata. Površ trećeg reda ima 10 koeficijenata, koliko i tačaka, pa (u opštem slučaju) prolazi tačno kroz sve tačke: šum nije uklonjen, model je preprilagođen i van tačaka može jako da osciluje.

4. (a) $C(2500) = 0{,}8\,(1 - 0{,}75 + 0{,}0625) = 0{,}25$, pa je $c_1 = 0{,}25/0{,}8 = 0{,}3125$ i $\hat{z}_0 = 1000 + 0{,}3125 \cdot (-200) = 937{,}5$. (b) $C(6000) = 0$, pa je $c_1 = 0$ i $\hat{z}_0 = m = 1000$: tačka van dometa ne nosi informaciju, pa je najbolja procjena srednja vrijednost.

5. $\sigma^2(c) = 0{,}8\,c^2 - 2 \cdot 0{,}25\,c + 0{,}8 = 0{,}8c^2 - 0{,}5c + 0{,}8$. Izvod $1{,}6c - 0{,}5 = 0$ daje $c^* = 0{,}3125$, što je baš težina krigovanja iz zadatka 4. Vrijednosti: $\sigma^2(0) = 0{,}8$, $\sigma^2(0{,}3125) = 0{,}8 - 0{,}3125 \cdot 0{,}25 \approx 0{,}722$, $\sigma^2(1) = 1{,}1$. Uzeti izmjerenu vrijednost kao procjenu ($c = 1$) je gore nego ne koristiti mjerenje uopšte.

6. $h = 1$: razlike $-1, -2, 1, -2$, zbir kvadrata 10, $N = 4$, pa $\hat{\gamma}(1) = 10/8 = 1{,}25$. $h = 2$: razlike $-3, -1, -1$, zbir kvadrata 11, $N = 3$, pa $\hat{\gamma}(2) = 11/6 \approx 1{,}83$.

Pojmovnik

BLUE najbolji linearni nepristrasni estimator; kriging je takav estimator.

Centrirana promjenljiva $Y = Z - m$, sa očekivanjem nula.

Domet rastojanje na kome korelacija vrijednosti nestaje.

Deklasterovanje smanjivanje težina grupisanih, međusobno korelisanih tačaka u krigovanju.

Efekat zaklanjanja mala težina tačke koja se nalazi iza bliže tačke, gledano iz tačke procjene.

Efekat grumena skok variograma u nuli (greška mjerenja i varijacija na malim rastojanjima).

Empirijski variogram procjena variograma iz parova izmjerenih tačaka.

Ekstrapolacija procjena vrijednosti izvan oblasti koju pokrivaju mjerenja.

IDW metod inverznih distanci: težinska sredina sa težinama $1/d^p$.

Interpolacija procjena vrijednosti u tački na osnovu mjerenja u okolnim tačkama istog regiona.

Kovarijansna funkcija funkcija $C(h)$ koja opisuje korelaciju vrijednosti na rastojanju h.

Kriging geostatistička metoda interpolacije čije težine zavise od prostorne korelacije podataka.

Obični kriging kriging sa nepoznatom srednjom vrijednošću i uslovom $\sum \lambda_i = 1$.

Plato vrijednost kojoj variogram teži; jednak varijansi $C(0)$.

Metoda najmanjih kvadrata izbor parametara modela koji minimizuje zbir kvadrata odstupanja.

Red trend površi najveći stepen polinoma kojim je površ opisana.

Regionalizovana promjenljiva veličina sastavljena od trenda, prostorno korelisane varijacije i šuma.

Rezidual razlika izmjerene vrijednosti i vrijednosti modela.

Stacionarnost konstantno očekivanje i kovarijansa koja zavisi samo od rastojanja.

Splajn površ sastavljena od glatko spojenih polinoma po djelovima.

Tisenovi poligoni podjela ravni na oblasti najbliže pojedinim tačkama uzorka.

Unakrsna provjera provjera modela izostavljanjem i ponovnom procjenom svake tačke.

Trend površ polinom $f(x, y)$ koji aproksimira opšti trend podataka.

Variogram funkcija $\gamma(h) = C(0) - C(h)$ koja mjeri različitost vrijednosti na rastojanju h.

Varijansa krigovanja najmanja varijansa greške, $\sigma^2_{SK} = C(0) - \sum c_i b_i$.

Literatura

[1] P. A. Burrough, R. A. McDonnell, C. D. Lloyd, *Principles of Geographical Information Systems*, 3. izdanje, Oxford University Press, 2015. (Poglavlja o interpolaciji i geostatistici.)

[2] E. H. Isaaks, R. M. Srivastava, *An Introduction to Applied Geostatistics*, Oxford University Press, 1989.

[3] W. R. Tobler, *A computer movie simulating urban growth in the Detroit region*, Economic Geography 46, 1970.